



UNIVERSIDAD ALFONSO X EL SABIO
FACULTAD BUSINESS&TECH

**Análisis Transcriptómico Diferencial y Enriquecimiento Funcional En Enfermedad
Renal Crónica Mediante Datos Públicos De Microarrays**

Cristian Alberto Arias Ramírez

TRABAJO FIN DE MÁSTER
Máster Universitario en Bioinformática
Madrid, 2026



UNIVERSIDAD ALFONSO X EL SABIO

Máster Universitario en Bioinformática

**Análisis Transcriptómico Diferencial y Enriquecimiento Funcional En Enfermedad
Renal Crónica Mediante Datos Públicos De Microarrays**

ALUMNO: Cristian Alberto Arias Ramírez

NP: 870902

TUTOR DEL TRABAJO: Prof. Julio Merelo

FECHA DE PRESENTACIÓN: junio 2026

Firma del director:

Firma del alumno:

Contenido

RESUMEN	4
CAPÍTULO 1.....	6
INTRODUCCIÓN AL TRABAJO FIN DE MÁSTER	6
1.1 Contexto general y relevancia de la enfermedad renal crónica	6
1.2 Justificación del proyecto	6
1.3 Bases fisiopatológicas y complejidad biológica de la enfermedad renal crónica.....	7
1.4 Limitaciones de los enfoques clínicos convencionales	7
1.5 Justificación del enfoque transcriptómico en la enfermedad renal crónica.....	8
1.6 Importancia de la bioinformática y la reproducibilidad	8
1.7 Estado actual de la investigación transcriptómica en enfermedad renal crónica	9
1.8 Limitaciones y perspectivas futuras del enfoque transcriptómico.....	9
1.9 Relevancia y objetivos generales del presente trabajo.....	10
CAPÍTULO 2.....	11
OBJETIVOS DEL TFM	11
CAPÍTULO 3.....	14
MARCO TEÓRICO	14
3.1. Fundamentos de la transcriptómica: microarrays, principios y limitaciones.....	14
3.1.1. Principio tecnológico de los microarrays	15
3.1.2. Ventajas de los microarrays en la investigación biomédica	16
3.1.3. Limitaciones inherentes a la tecnología de microarrays	16
3.2. Transcriptómica aplicada al tejido renal en la enfermedad renal crónica	17
3.2.1. Compartimentalización funcional: glomérulo vs. túbulo-intersticio	17
3.2.2. Procesos biológicos clave identificados por transcriptómica en ERC	18
3.3. Bioinformática aplicada al análisis de expresión génica.....	20
3.3.1. Normalización de datos de microarrays.....	20
3.3.2. Análisis de expresión diferencial: modelos lineales y limma	21
3.3.3. Corrección para comparaciones múltiples (FDR).....	21
3.4. Enriquecimiento funcional y análisis de rutas.....	22
3.4.1. Bases de datos de conocimiento biológico: Gene Ontology (GO) y KEGG.....	22
3.4.2. Principio del análisis de enriquecimiento.....	23
3.4.3. Interpretación biológica de los resultados de enriquecimiento	24
CAPÍTULO 4.....	25
MARCO METODOLÓGICO	25
4.1 Diseño del estudio.....	25

4.2 Fuente de datos y criterios de selección	26
4.2.1 Repositorio de datos	26
4.2.2 Selección del dataset	27
Criterios de inclusión	27
Criterios de exclusión.....	27
4.3 Preprocesamiento y control de calidad.....	28
4.3.1 Lectura y normalización de datos	28
4.3.2 Evaluación de calidad	28
4.4 Análisis de expresión diferencial	29
4.4.1 Modelado estadístico mediante limma	29
4.4.2 Corrección por comparaciones múltiples	29
4.4.3 Selección de genes diferencialmente expresados	30
4.5 Análisis de enriquecimiento funcional	30
4.6 Reproducibilidad computacional y trazabilidad	31
4.7 Justificación metodológica	32
CAPÍTULO 5.....	33
RESULTADOS Y DISCUSIÓN	33
5.1 Control de calidad y análisis exploratorio	33
5.1.1 Introducción al control de calidad del dataset.....	33
5.1.2 Evaluación de la distribución de la expresión génica	34
5.1.3 Análisis de componentes principales (PCA)	36
5.1.4 Análisis mediante heatmap de genes variables	37
5.1.5 Evaluación global del control de calidad	38
5.2.1 Identificación de genes diferencialmente expresados	39
5.2.2 Visualización global mediante volcano plot.....	41
5.2.4 Interpretación biológica	42
5.3 Análisis de enriquecimiento funcional	43
5.3.1 GO Proceso Biológico.....	43
5.3.2 GO Componente Celular	44
5.3.3 GO Función Molecular	45
5.3.4 Rutas KEGG	46
5.4 Integración fisiopatológica y mensaje central del estudio	47
5.5 Discusión crítica en el contexto de la literatura.....	48
5.6 Micro-crítica de los resultados y consideraciones metodológicas	50
5.7 Implicaciones traslacionales y relevancia del estudio	51
5.8 Síntesis final del capítulo	52

CAPÍTULO 6.....	53
CONCLUSIONES	53
6.1 Síntesis de los hallazgos principales	53
6.2 Implicaciones clínicas y científicas	54
6.3 Implicaciones metodológicas y valor del enfoque bioinformático	56
6.4 Limitaciones del estudio	56
6.5 Líneas futuras de investigación	57
6.6 Conclusión final	57
7. Declaración sobre el uso de herramientas de inteligencia artificial generativa.....	58
ANEXO I.	63
Figura A1. Density plot de las distribuciones de expresión génica normalizada.....	63
Figura A2. Heatmap extendido de los 100 genes con mayor variabilidad	64
Tabla 5.1. Top 20 genes diferencialmente expresados en ERC.....	65
ANEXO II.	66
1. Introducción	66
2. Descripción general del pipeline	66
3. Estructura funcional	67
4. Ejecución del pipeline	67
5. Entradas y salidas	67
6. Consideraciones finales	68
ANEXO III. REPRODUCIBILIDAD DEL ANÁLISIS BIOINFORMÁTICO	68
1. Entorno computacional	68
2. Estructura del proyecto	68
3. Ejecución del pipeline	69
4. Control de entorno	69
5. Resultados reproducibles	70
6. Restauración	70
7. Declaración de reproducibilidad.....	70
A3.1 Validación del proyecto	71
A3.2 Normalización	71
A3.3 Expresión diferencial.....	71
A3.4 Enriquecimiento	71

RESUMEN

Introducción:

La enfermedad renal crónica (ERC) constituye un problema de salud pública global, asociado a una elevada morbilidad y a un importante impacto socioeconómico. A pesar de los avances clínicos, los mecanismos moleculares implicados en su progresión no están completamente caracterizados. El análisis transcriptómico permite estudiar de forma global los cambios en la expresión génica asociados a la enfermedad y generar hipótesis biológicas relevantes.

Metodología:

Se realizó un estudio bioinformático utilizando datos públicos de expresión génica obtenidos del repositorio Gene Expression Omnibus (GEO), correspondientes a tejido renal humano analizado mediante microarrays. Tras la curación de metadatos y la normalización de la expresión, se aplicó un análisis de expresión diferencial mediante el paquete limma. Posteriormente, los genes diferencialmente expresados se sometieron a análisis de enriquecimiento funcional de Gene Ontology (GO) y rutas KEGG utilizando clusterProfiler.

Resultados:

Se identificaron 365 genes diferencialmente expresados entre los grupos ERC y control ($FDR \leq 0,05$; $|\log FC| \geq 1$). El análisis de enriquecimiento reveló una alteración significativa de procesos biológicos relacionados con inflamación, remodelado tisular y función tubular renal, así como de rutas metabólicas y de señalización implicadas en la fisiopatología de la ERC.

Conclusiones:

El análisis transcriptómico permitió identificar firmas moleculares relevantes asociadas a la ERC, aportando una visión integradora de los mecanismos biológicos implicados. Estos resultados refuerzan el potencial del enfoque transcriptómico como herramienta para la investigación en nefrología de precisión y el desarrollo de futuras estrategias diagnósticas y terapéuticas.

Palabras clave: enfermedad renal crónica; transcriptómica; microarrays; expresión génica; bioinformática.

ABSTRACT

Introduction:

Chronic kidney disease (CKD) is a major global public health problem associated with high morbidity, mortality, and significant socioeconomic burden. Despite advances in clinical management, the molecular mechanisms underlying disease progression remain incompletely understood. Transcriptomic analysis enables the comprehensive evaluation of gene expression changes and provides valuable insights into the biological processes involved in CKD.

Methodology:

A bioinformatic study was conducted using publicly available gene expression data from the Gene Expression Omnibus (GEO), corresponding to human kidney tissue analyzed by microarrays. Following metadata curation, the expression matrix was normalized using quantile normalization implemented through `limma::normalizeBetweenArrays()`, and multiple probes mapping to the same gene were collapsed using the median expression value prior to differential expression analysis. Subsequently, differentially expressed genes were subjected to functional enrichment analysis based on Gene Ontology (GO) terms and KEGG pathways using *clusterProfiler*.

Results:

A total of 365 differentially expressed genes were identified between CKD and control samples ($\text{FDR} \leq 0.05$; $|\log_2\text{FC}| \geq 1$). Functional enrichment analysis revealed significant alterations in biological processes related to inflammation, extracellular matrix organization, and renal tubular function. Key signaling and metabolic pathways implicated in CKD pathophysiology were also identified, including those associated with fibrosis and cellular stress responses.

Conclusions:

This study highlights an integrated transcriptional program underlying CKD progression, characterized by coordinated activation of inflammatory and profibrotic pathways alongside loss of specialized renal functions. These findings reinforce the value of transcriptomic approaches in advancing precision nephrology and improving the understanding of complex renal diseases.

Keywords: chronic kidney disease; transcriptomics; microarrays; gene expression; bioinformatics.

CAPÍTULO 1.

INTRODUCCIÓN AL TRABAJO FIN DE MÁSTER

1.1 Contexto general y relevancia de la enfermedad renal crónica

La enfermedad renal crónica (ERC) se define como la presencia de alteraciones estructurales o funcionales del riñón con una duración superior a tres meses y constituye uno de los principales problemas de salud pública a nivel mundial. Se estima que afecta aproximadamente al 10–13 % de la población adulta global, con una prevalencia creciente asociada al envejecimiento poblacional y al aumento de factores de riesgo como la diabetes mellitus, la hipertensión arterial y la obesidad.

Desde el punto de vista clínico, la ERC se caracteriza por una pérdida progresiva e irreversible de la función renal que puede culminar en enfermedad renal terminal, con necesidad de terapias de reemplazo renal como la diálisis o el trasplante. Sin embargo, incluso en estadios tempranos, la ERC se asocia a un incremento significativo del riesgo cardiovascular, hospitalizaciones recurrentes y deterioro de la calidad de vida, lo que contribuye de manera relevante a la morbilidad global.

El impacto socioeconómico de la ERC es considerable. Las terapias de reemplazo renal representan uno de los mayores costes recurrentes para los sistemas sanitarios, a pesar de afectar a una proporción relativamente pequeña de la población. A ello se suman los costes indirectos derivados de la pérdida de productividad laboral, la discapacidad y la necesidad de cuidados prolongados, lo que subraya la necesidad de mejorar las estrategias de prevención, diagnóstico precoz y estratificación del riesgo.

1.2 Justificación del proyecto

La justificación del presente Trabajo Fin de Máster se fundamenta en la elevada relevancia clínica y social de la ERC, así como en la necesidad de profundizar en la comprensión de los mecanismos moleculares implicados en su desarrollo y progresión. A pesar de los avances en el manejo clínico, persisten importantes limitaciones en la identificación temprana de pacientes con alto riesgo de progresión y en la personalización de las estrategias terapéuticas.

En este contexto, el análisis de datos transcriptómicos públicos constituye una alternativa viable y eficiente para la investigación biomédica. La reutilización de datos disponibles en repositorios internacionales permite superar limitaciones de infraestructura experimental, favorece la reproducibilidad y promueve principios de ciencia abierta. Asimismo, el desarrollo de un pipeline bioinformático reproducible garantiza la trazabilidad del análisis y responde a los estándares actuales de calidad científica.

1.3 Bases fisiopatológicas y complejidad biológica de la enfermedad renal crónica

La ERC no representa una entidad patológica única, sino un conjunto heterogéneo de procesos que convergen en un fenotipo común de deterioro renal progresivo. A nivel fisiopatológico, la enfermedad implica la interacción compleja entre inflamación crónica, fibrosis intersticial, disfunción endotelial y alteraciones en la señalización celular, lo que conduce a la pérdida progresiva de nefronas funcionales y a la remodelación estructural del tejido renal.

La heterogeneidad clínica y biológica de la ERC plantea importantes desafíos para su estudio y manejo. Pacientes con etiologías distintas pueden presentar trayectorias de progresión similares, mientras que individuos con diagnósticos clínicos comparables pueden mostrar evoluciones divergentes. Esta variabilidad sugiere la existencia de mecanismos moleculares subyacentes diferenciales que no son capturados adecuadamente por los marcadores clínicos tradicionales.

1.4 Limitaciones de los enfoques clínicos convencionales

A pesar de los avances en el manejo clínico de la ERC, las herramientas diagnósticas y pronósticas actuales presentan limitaciones significativas. Parámetros como la tasa de filtrado glomerular estimada (TFGe) y la albuminuria, aunque fundamentales en la práctica clínica, ofrecen una visión parcial del estado biológico del riñón y no reflejan de manera directa los procesos moleculares subyacentes a la enfermedad.

Estas limitaciones dificultan la identificación temprana de pacientes con mayor riesgo de progresión y la implementación de intervenciones personalizadas. En este sentido, resulta necesario incorporar enfoques analíticos capaces de capturar la complejidad molecular de la ERC y de aportar información adicional a la proporcionada por los marcadores clínicos convencionales.

1.5 Justificación del enfoque transcriptómico en la enfermedad renal crónica

En los últimos años, el avance de las tecnologías ómicas ha permitido abordar el estudio de la ERC desde una perspectiva molecular integradora. En particular, la transcriptómica ofrece la posibilidad de analizar de manera global los patrones de expresión génica asociados a distintos estadios y fenotipos de la enfermedad, proporcionando información clave sobre los procesos biológicos implicados en su desarrollo y progresión.

A diferencia de los enfoques clínicos tradicionales, el análisis transcriptómico permite identificar alteraciones moleculares tempranas que pueden preceder a los cambios clínicos evidentes. Este enfoque resulta especialmente relevante en una enfermedad heterogénea como la ERC, en la que múltiples vías patogénicas pueden converger en un mismo fenotipo clínico.

El uso de datos transcriptómicos públicos, disponibles en repositorios internacionales como Gene Expression Omnibus, constituye además una estrategia eficiente y reproducible para la investigación biomédica. La reutilización de estos datos facilita la validación de hallazgos previos, promueve la ciencia abierta y permite desarrollar estudios bioinformáticos robustos incluso en contextos con limitaciones de infraestructura experimental.

1.6 Importancia de la bioinformática y la reproducibilidad

La correcta interpretación de los datos transcriptómicos depende de la aplicación de pipelines bioinformáticos robustos y reproducibles. La bioinformática desempeña un papel central en la integración, análisis y visualización de grandes volúmenes de datos de expresión génica, garantizando la trazabilidad y fiabilidad de los resultados obtenidos.

En el contexto actual de la investigación biomédica, la reproducibilidad se ha convertido en un criterio esencial de calidad científica. La documentación exhaustiva del entorno computacional, el uso de herramientas estandarizadas y la adopción de principios de ciencia abierta permiten que los análisis puedan ser replicados y validados por otros investigadores, fortaleciendo la credibilidad de los hallazgos obtenidos.

1.7 Estado actual de la investigación transcriptómica en enfermedad renal crónica

La incorporación de tecnologías transcriptómicas al estudio de la ERC ha transformado la comprensión de su patogenia, pasando de una visión centrada en marcadores funcionales a un enfoque integrador basado en la biología de sistemas. En la última década, la acumulación de datos de expresión génica procedentes de tejido renal, sangre y orina ha permitido esbozar un mapa molecular de la ERC cada vez más detallado.

Inicialmente, la mayoría de los estudios se basaron en el uso de microarrays, una tecnología que permitió los primeros análisis globales del transcriptoma renal y la identificación de firmas génicas asociadas a la fibrosis tubulointersticial y a la progresión de la enfermedad. Posteriormente, la introducción de la secuenciación de ARN (RNA-seq) amplió significativamente el rango dinámico de detección y la capacidad para identificar nuevos transcritos, isoformas alternativas y ARN no codificantes con potencial relevancia patogénica.

Más recientemente, el desarrollo de tecnologías de transcriptómica de célula única ha permitido caracterizar la heterogeneidad celular del riñón con un nivel de resolución sin precedentes, identificando subpoblaciones celulares y estados transcripcionales específicos asociados a la ERC. No obstante, estas aproximaciones presentan desafíos técnicos y económicos que limitan su aplicación generalizada, lo que hace que los estudios transcriptómicos en bulk continúen siendo una herramienta fundamental para el análisis de grandes cohortes.

1.8 Limitaciones y perspectivas futuras del enfoque transcriptómico

A pesar de los avances alcanzados, la investigación transcriptómica en ERC enfrenta limitaciones importantes. La heterogeneidad de las muestras humanas, la diversidad etiológica de la enfermedad y la variabilidad técnica entre estudios representan fuentes de sesgo que deben ser cuidadosamente controladas. Además, la integración de datos procedentes de diferentes plataformas y cohortes requiere métodos estadísticos avanzados para garantizar la robustez de las conclusiones.

Por otro lado, existe una brecha entre el descubrimiento de firmas transcripcionales y su validación funcional o traslacional. La identificación de genes diferencialmente expresados no implica necesariamente un papel causal en la progresión de la enfermedad, lo que subraya la necesidad de estudios funcionales complementarios.

En este contexto, el futuro de la investigación en ERC apunta hacia la integración de múltiples capas de información molecular, combinando transcriptómica con genómica, epigenómica y proteómica. Esta aproximación multi-ómica constituye la base para avanzar hacia una medicina de precisión en nefrología, donde la estratificación de pacientes pueda realizarse en función de perfiles moleculares específicos y no únicamente de parámetros clínicos convencionales.

1.9 Relevancia y objetivos generales del presente trabajo

A la luz de lo expuesto, el presente Trabajo Fin de Máster se plantea como un estudio de investigación aplicada orientado a analizar las alteraciones transcriptómicas asociadas a la enfermedad renal crónica mediante un enfoque bioinformático reproducible. El trabajo tiene como objetivo principal identificar patrones de expresión génica diferencial y contextualizarlos en términos de procesos biológicos y rutas moleculares relevantes para la patogenia de la ERC.

Asimismo, este estudio pretende servir como ejemplo práctico de la aplicación de técnicas de bioinformática en el ámbito de la nefrología, contribuyendo al desarrollo de enfoques reproducibles y alineados con los principios de ciencia abierta. En conjunto, el trabajo se sitúa en la intersección entre la nefrología clínica y la bioinformática, abordando una problemática de alta relevancia sanitaria y científica mediante herramientas analíticas modernas y rigurosas.

CAPÍTULO 2.

OBJETIVOS DEL TFM

Una vez establecido el marco conceptual que justifica la aplicación de la transcriptómica al estudio de la enfermedad renal crónica, así como el estado actual de la investigación en este campo, el presente capítulo define los objetivos que guiarán el desarrollo del trabajo. Estos objetivos se han formulado para ser específicos, alcanzables y relevantes, asegurando que cada etapa del análisis contribuya de manera significativa a la comprensión de las bases moleculares de la ERC.

2.1 Objetivo general

El propósito central de este Trabajo Fin de Máster **es** analizar las diferencias **en los** perfiles de expresión génica entre tejido renal de pacientes con enfermedad renal crónica y controles sanos, mediante la aplicación de un enfoque transcriptómico y bioinformático robusto y reproducible.

Este objetivo general implica no solo la identificación de genes con expresión alterada, sino también la interpretación biológica de dichos cambios en el contexto de la fisiopatología renal. Se busca, por tanto, trascender la mera obtención de un listado de genes para generar conocimiento sobre los procesos moleculares alterados en la ERC. La consecución de este propósito se articulará a través de una serie de objetivos específicos, diseñados para abordar de manera lógica y secuencial las distintas fases del análisis de datos transcriptómicos.

2.2 Objetivos específicos

Para alcanzar la meta general propuesta, se han definido los siguientes objetivos específicos, que estructuran el flujo de trabajo del proyecto:

2.2.1 Seleccionar y descargar un conjunto de datos transcriptómicos públicos de tejido renal humano.

El primer paso consiste en la identificación y adquisición de una fuente de datos adecuada para responder a la pregunta planteada. Para ello, se explorará el repositorio público **Gene Expression Omnibus (GEO)** en busca de conjuntos de datos de transcriptómica (procedentes de microarrays o RNA-seq) que cumplan con criterios predefinidos: (i) muestras de tejido renal humano, (ii) inclusión tanto de pacientes diagnosticados con ERC como de individuos control sanos, y (iii) disponibilidad de los datos crudos o procesados, junto con los metadatos clínicos necesarios para la correcta clasificación de las muestras. Este enfoque se alinea con los principios de ciencia abierta y reutilización de datos discutidos en la introducción.

2.2.2 Realizar la curación de metadatos y la normalización de los datos de expresión génica.

Una vez obtenidos los datos, es imprescindible someterlos a un riguroso control de calidad y procesamiento. Este objetivo comprende dos tareas fundamentales:

Curación de metadatos: Implica la revisión, estandarización y asignación inequívoca de cada muestra a su grupo experimental correspondiente (ERC vs. control), un paso crítico para la validez del análisis posterior.

Normalización de los datos: Normalización de los datos: Se aplicarán técnicas estadísticas específicas según la naturaleza de los datos y la estrategia analítica seleccionada, con el objetivo de eliminar la variabilidad técnica no biológica y hacer comparables los niveles de expresión entre las distintas muestras.

.

2.2.3 Identificar genes diferencialmente expresados entre los grupos ERC y control.

Con la matriz de expresión depurada y normalizada, se procederá a la comparación sistemática de los perfiles transcripcionales. Mediante la aplicación de métodos estadísticos apropiados (como el t-test moderado o modelos lineales generalizados, implementados en paquetes de R/Bioconductor como **limma**), se identificarán aquellos genes cuya expresión muestre una diferencia significativa entre las muestras de pacientes con ERC y los controles. Se establecerán umbrales de significación estadística (p-valor ajustado) y de magnitud del cambio (fold-change) para seleccionar el conjunto de genes diferencialmente expresados (GDE) más relevantes.

2.2.4 Analizar el enriquecimiento funcional de los genes diferencialmente expresados mediante Gene Ontology y rutas KEGG.

La identificación de GDE constituye un punto de partida, pero no un fin en sí mismo. Para dotar de significado biológico a los resultados, se realizará un análisis de **enriquecimiento funcional**. Utilizando herramientas bioinformáticas como **clusterProfiler**, se evaluará si los genes identificados están sobrerrepresentados en categorías biológicas específicas de la base de datos **Gene Ontology (GO)** (procesos biológicos, funciones moleculares y componentes celulares) y en rutas metabólicas y de señalización de la enciclopedia **KEGG**. Este análisis permitirá contextualizar los hallazgos en el marco de los procesos fisiopatológicos conocidos de la ERC, como la inflamación, la fibrosis o la respuesta al estrés, tal como se discutió en los apartados iniciales.

2.2.5 Generar figuras y tablas interpretables para su integración en un manuscrito científico.

El último objetivo, pero no por ello menos importante, se centra en la comunicación efectiva de los resultados. Se elaborarán representaciones gráficas claras e informativas que resuman los hallazgos principales: mapas de calor y gráficos de volcán (volcano plots) para visualizar los patrones de expresión, diagramas de barras para mostrar los términos GO y las rutas KEGG más significativamente enriquecidas, y tablas resumen con los estadísticos de los GDE más relevantes.

Este paso es crucial para que los resultados sean comprensibles, evaluables y estén listos para su potencial inclusión en un manuscrito científico o comunicación en un congreso, cumpliendo así con el objetivo final de contribuir al conocimiento del área.

En conjunto, el desarrollo secuencial de estos objetivos específicos permitirá cumplir con el propósito general del TFM, ofreciendo una visión integrada de las alteraciones transcriptómicas asociadas a la ERC y sentando las bases para futuras investigaciones traslacionales en el ámbito de la nefrología de precisión.

CAPÍTULO 3.

MARCO TEÓRICO

El presente capítulo tiene como objetivo establecer las bases conceptuales, tecnológicas y metodológicas que sustentan este trabajo. Se abordarán los fundamentos de la transcriptómica y las principales tecnologías para su estudio, con especial énfasis en los microarrays. A continuación, se profundizará en la aplicación específica de la transcriptómica al tejido renal en el contexto de la enfermedad renal crónica, detallando los procesos fisiopatológicos identificados mediante esta aproximación.

Finalmente, se expondrán los fundamentos bioinformáticos para el análisis de datos de expresión, incluyendo la normalización, los modelos estadísticos para la detección de genes diferencialmente expresados y las metodologías para el enriquecimiento funcional y la interpretación biológica de los resultados.

3.1. Fundamentos de la transcriptómica: microarrays, principios y limitaciones

La transcriptómica, como se introdujo previamente, es la disciplina que estudia el conjunto completo de transcritos de ARN presentes en una célula, tejido u organismo en un momento y condición determinados. Para llevar a cabo este estudio, se han desarrollado diversas tecnologías de alto rendimiento, siendo los microarrays una de las más consolidadas y con mayor legado de datos históricos. Dado que el presente trabajo se basa en el reanálisis de datos públicos, muchos de ellos procedentes de esta plataforma,

resulta esencial comprender sus fundamentos técnicos, sus ventajas y sus limitaciones inherentes.

3.1.1. Principio tecnológico de los microarrays

La tecnología de microarrays de expresión se fundamenta en el principio de **hibridación competitiva**. Un microarray es un soporte sólido, generalmente de vidrio o silicio, de dimensiones reducidas (similares a un portaobjetos), sobre el que se inmovilizan, de manera ordenada y en posiciones conocidas, miles o cientos de miles de sondas de ADN. Cada sonda es un fragmento de ADN de cadena sencilla, de secuencia conocida, diseñado para ser complementario a un transcrito diana específico (por ejemplo, un exón de un gen concreto).

El proceso experimental para generar los datos consta de varias etapas:

1. **Extracción y purificación del ARN:** Se obtiene el ARN total de las muestras biológicas de interés (en este caso, tejido renal).
2. **Retrotranscripción y marcaje:** El ARN se retrotranscribe a ADN complementario (ADNc), incorporando durante el proceso nucleótidos marcados con fluorocromos (generalmente Cy3 y Cy5).
3. **Hibridación:** La muestra de ADNc marcada se deposita sobre el microarray y se incuba para permitir que las secuencias complementarias se hibriden con sus sondas correspondientes. Cuanto más abundante sea un transcrito en la muestra original, más moléculas de ADNc marcado estarán disponibles para hibridar con su sonda específica.
4. **Lavado y escaneado:** Tras la hibridación, se lavan los arrays para eliminar el ADNc no unido específicamente. A continuación, un escáner láser excita los fluorocromos y mide la intensidad de fluorescencia emitida en cada punto del array.
5. **Cuantificación:** La intensidad de fluorescencia en cada sonda es directamente proporcional a la abundancia del transcrito correspondiente en la muestra original. Estas intensidades se registran y constituyen la materia prima para los análisis bioinformáticos posteriores.

3.1.2. Ventajas de los microarrays en la investigación biomédica

A pesar del auge de tecnologías más modernas, los microarrays presentan una serie de ventajas que explican su uso continuado y la vigencia de los datos que generan:

Madurez tecnológica y estandarización: Es una tecnología ampliamente validada y estandarizada, con protocolos bien establecidos y una variabilidad técnica conocida y manejable.

Coste relativamente bajo: El coste por muestra es significativamente inferior al del RNA-seq, lo que permite analizar cohortes de gran tamaño con presupuestos limitados.

Análisis bioinformático consolidado: Los pipelines de análisis para datos de microarrays están muy desarrollados, son robustos y requieren una potencia computacional moderada. Paquetes como `limma` (que se detallará más adelante) fueron diseñados inicialmente para este tipo de datos y funcionan de manera óptima.

Existencia de vastos repositorios de datos públicos: Como se ha mencionado, repositorios como GEO albergan decenas de miles de estudios basados en microarrays. Esta gran cantidad de datos históricos constituye un recurso invaluable para estudios de reanálisis, validación cruzada y meta-análisis, como el que se plantea en este TFM.

3.1.3. Limitaciones inherentes a la tecnología de microarrays

Sin embargo, es crucial ser consciente de las limitaciones de los microarrays para interpretar correctamente los resultados y contextualizar su alcance:

Dependencia del conocimiento previo: Los microarrays solo pueden detectar transcritos correspondientes a las sondas que han sido diseñadas e impresas en el array. Esto impide el descubrimiento de nuevos genes, nuevas isoformas de splicing o ARN no codificantes que no estuvieran contemplados en el diseño original.

Rango dinámico limitado: La relación entre la intensidad de fluorescencia y la abundancia real del transcrito no es lineal en un rango muy amplio. Esto dificulta la cuantificación precisa de genes con expresión muy baja (se pierden en el ruido de fondo) o extremadamente alta (saturación de la señal).

Problemas de hibridación cruzada: Puede producirse hibridación inespecífica, donde un transcrito se une a una sonda parecida pero no idéntica a su secuencia, generando señales erróneas y ruido de fondo.

En resumen, los microarrays son una tecnología robusta y fiable para la **cuantificación de transcritos conocidos** en un **marco comparativo**, como es la identificación de genes diferencialmente expresados entre dos condiciones. Es la herramienta adecuada para el objetivo planteado en este trabajo, siempre que se tenga en cuenta su alcance y limitaciones.

3.2. Transcriptómica aplicada al tejido renal en la enfermedad renal crónica

La aplicación de la transcriptómica al estudio del riñón ha permitido ir más allá de la descripción histológica clásica para explorar los eventos moleculares que ocurren en los diferentes compartimentos del órgano y que subyacen a la progresión de la ERC.

3.2.1. Compartimentalización funcional: glomérulo vs. túbulo-intersticio

El riñón es un órgano altamente complejo y compartimentalizado, tanto estructural como funcionalmente. El **glomérulo** es la unidad de filtración, una intrincada red capilar responsable de la ultrafiltración de la sangre.

Las enfermedades glomerulares (como la glomerulonefritis o la nefropatía diabética) suelen ser el evento iniciador de muchas ERC. Por otro lado, el compartimento **tubulointersticial**, que comprende los túbulos renales (responsables de la reabsorción y secreción de solutos) y el intersticio circundante (tejido de soporte que alberga fibroblastos y vasos sanguíneos), ha sido identificado como el principal determinante de la progresión de la enfermedad, independientemente de la causa inicial.

Los estudios transcriptómicos que han analizado por separado estos compartimentos (mediante microdissección por captura láser, por ejemplo) han revelado perfiles de expresión génica notablemente distintos:

En el **glomérulo**, las firmas moleculares en ERC suelen estar dominadas por genes relacionados con la **lesión de podocitos** (células epiteliales especializadas que forman la barrera de filtración), la **inflamación** y la **activación del complemento**.

En el **túbulo-intersticio**, los cambios transcripcionales son más complejos e incluyen la activación de programas de **reparación maladaptativa**, **senescencia celular**, **metabolismo alterado** y, crucialmente, una potente respuesta **profibrótica**. La expresión de genes como las quimiocinas (ej. CCL2), citoquinas profibróticas (ej. TGFB1) y proteínas de matriz extracelular (ej. colágenas tipo I y III, fibronectina) en este compartimento se correlaciona fuertemente con el deterioro de la función renal.

3.2.2. Procesos biológicos clave identificados por transcriptómica en ERC

El análisis global de la expresión génica ha permitido sistematizar los procesos biológicos alterados en la ERC, confirmando y ampliando el conocimiento fisiopatológico clásico.

Fibrosis renal: Es el proceso final común de la ERC progresiva. A nivel transcriptómico, la fibrosis se caracteriza por la sobreexpresión masiva de genes que codifican **proteínas de matriz extracelular** (colágenas, lamininas, fibronectina), así como de genes implicados en su remodelación (metaloproteasas de matriz, MMPs, y sus inhibidores, TIMPs).

También se observa la activación de genes marcadores de **miofibroblastos** (como ACTA2, que codifica la α -actina de músculo liso), las células efectoras de la fibrosis, cuya diferenciación está impulsada por la señalización de TGF- β /SMAD.

Inflamación crónica: Un sello distintivo de la ERC es la presencia de un infiltrado inflamatorio persistente en el tejido renal. Los transcriptomas renales de pacientes con ERC muestran una marcada sobreexpresión de genes relacionados con la **respuesta inmune e inflamatoria**. Esto incluye quimiocinas (CCL2, CCL5) que reclutan monocitos y linfocitos, citoquinas proinflamatorias (IL1B, IL6, TNF) y genes de presentación antigénica (moléculas del MHC de clase II). La activación de vías de señalización como la de NF- κ B es un denominador común en estos perfiles.

Estrés oxidativo y respuesta a hipoxia: El daño renal conduce a una alteración de la perfusión tisular y a un aumento del estrés oxidativo. Esto se refleja en la expresión alterada de genes implicados en la **respuesta a especies reactivas de oxígeno** y en la adaptación a la **hipoxia**, como los factores inducibles por hipoxia (HIF1A) y sus genes diana (ej. VEGF, EPO).

Disfunción metabólica tubular: Los túbulos proximales, con una alta demanda energética para los procesos de transporte, son especialmente vulnerables. La transcriptómica ha revelado una **disminución coordinada de la expresión genes implicados en el metabolismo de ácidos grasos** y otros procesos metabólicos en las células tubulares dañadas, un fenómeno conocido como "displasia metabólica" que contribuye a la pérdida de función y a la atrofia tubular.

En conjunto, estos perfiles transcriptómicos demuestran que la ERC es el resultado de la interacción dinámica entre inflamación, estrés celular y un proceso de reparación aberrante que conduce a la fibrosis, consolidando al túbulo-intersticio como el epicentro de la progresión de la enfermedad.

3.3. Bioinformática aplicada al análisis de expresión génica

Los datos brutos generados por los microarrays no son directamente interpretables. Requieren de un procesamiento bioinformático riguroso para convertirlos en información biológica fiable. Este proceso consta de varias etapas críticas.

3.3.1. Normalización de datos de microarrays

La normalización es un paso esencial cuyo objetivo es eliminar la **variabilidad técnica no biológica** entre las muestras para que las diferencias observadas reflejen únicamente cambios biológicos reales. Esta variabilidad puede deberse a diferencias en la eficiencia de la retrotranscripción, del marcaje con fluorocromos, de la hibridación o en la sensibilidad del escáner al leer diferentes arrays.

Para datos de microarrays de una sola canal (como los de Affymetrix), uno de los métodos de normalización más utilizados y robustos es el algoritmo **RMA (Robust Multi-array Average)**. RMA realiza tres operaciones fundamentales:

Corrección del ruido de fondo: Ajusta las intensidades para eliminar la señal de fondo inespecífica.

Normalización cuantílica: Hace que la distribución de las intensidades de todos los arrays sea idéntica, asumiendo que la mayoría de los genes no cambian su expresión entre condiciones y que las diferencias en la distribución global son artefactos técnicos.

Resumen de sondas: Calcula un único valor de expresión para cada gen a partir de las múltiples sondas que lo representan en el array, utilizando un modelo logarítmico aditivo.

El resultado de la normalización RMA es una matriz de expresión génica log2-transformada, donde los valores son comparables entre todas las muestras y están listos para el análisis estadístico.

3.3.2. Análisis de expresión diferencial: modelos lineales y limma

Una vez obtenida la matriz de expresión normalizada, el siguiente paso es identificar los genes cuya expresión varía significativamente entre las condiciones de interés (ERC vs. control). El paquete **limma** (**Linear Models for Microarray and RNA-Seq Data**), parte del proyecto Bioconductor en R, es uno de los métodos más empleados y aceptados para este fin (Ritchie et al., 2015).

La fortaleza de **limma** reside en su enfoque estadístico, que combina **modelos lineales** con un método de **estadística bayesiana empírica**.

Para cada gen, se ajusta un modelo lineal que explica su nivel de expresión en función de las condiciones experimentales (por ejemplo, $\text{expresión} \sim \text{condición}$).

limma estima la varianza de la expresión para cada gen. En experimentos con pocas muestras, estas estimaciones individuales pueden ser muy inestables.

El componente bayesiano empírico "toma prestada" información de todos los genes para **moderar o estabilizar las estimaciones de varianza**. Esto significa que la varianza estimada para cada gen se acerca un poco a la varianza promedio de todos los genes, lo que resulta en pruebas estadísticas más robustas y fiables, especialmente para genes con expresión poco variable o en estudios con tamaño muestral reducido.

El resultado del análisis con **limma** es, para cada gen, un **fold change** (cambio en veces, que indica la magnitud de la diferencia) y un **p-valor** (que indica la significación estadística de esa diferencia).

3.3.3. Corrección para comparaciones múltiples (FDR)

Al realizar miles de pruebas estadísticas simultáneamente (una por cada gen en el array), se incrementa drásticamente la probabilidad de obtener falsos positivos (error de Tipo I). Si se utilizara un p-valor estándar de 0.05, se esperaría que un 5% de los genes no diferencialmente expresados aparecieran como significativos por azar, lo que en un array de 20,000 genes supondría 1,000 falsos positivos.

Para controlar este problema, es necesario aplicar una **corrección para comparaciones múltiples**. El método más utilizado en transcriptómica es el control de la **tasa de falsos descubrimientos (FDR, False Discovery Rate)**, propuesto por Benjamini y Hochberg (1995). A diferencia de métodos más conservadores que controlan la probabilidad de tener un solo falso positivo (FWER, Family-Wise Error Rate), el FDR controla la **proporción esperada de falsos positivos entre los genes declarados como significativos**. Es decir, si se selecciona un conjunto de 100 genes con un FDR del 5%, se espera que, de media, 5 de ellos sean falsos positivos.

En la práctica, el análisis con **limma** proporciona tanto el p-valor original como el **p-valor ajustado (adj.P.Val)**, que ya incorpora la corrección por FDR. Este último es el valor que se utiliza para seleccionar la lista final de genes diferencialmente expresados, garantizando la robustez de los hallazgos.

3.4. Enriquecimiento funcional y análisis de rutas

La identificación de una larga lista de genes diferencialmente expresados (GDE) es solo el primer paso. Para comprender el significado biológico de estos cambios, es necesario recurrir al análisis de enriquecimiento funcional, que permite contextualizar los GDE en procesos biológicos y rutas moleculares conocidas.

3.4.1. Bases de datos de conocimiento biológico: Gene Ontology (GO) y KEGG

Existen dos recursos fundamentales y ampliamente utilizados para este fin:

Gene Ontology (GO) (Ashburner et al., 2000): Es un proyecto de bioinformática que proporciona un vocabulario controlado y dinámico para describir las propiedades de los genes y sus productos en cualquier organismo. Se organiza en tres ontologías independientes:

Proceso Biológico (BP, Biological Process): Describe el objetivo biológico al que contribuye el gen, como "proceso de fibrosis renal" o "respuesta inflamatoria".

Función Molecular (MF, Molecular Function): Describe la actividad a nivel molecular, como "unión a TGF- β " o "actividad de collagenasa".

Componente Celular (CC, Cellular Component): Indica el lugar de la célula donde el gen es activo, como "matriz extracelular" o "membrana plasmática".

KEGG (Kyoto Encyclopedia of Genes and Genomes) (Kanehisa et al., 2021): Es una colección de bases de datos que integra información genómica, química y sistémica. Su recurso más utilizado es la base de datos de rutas (pathway maps), que son diagramas moleculares de interacciones, reacciones y relaciones para procesos celulares y de organismos, como la "vía de señalización de TGF-beta", la "ruta de NF-kappa B" o el "metabolismo de ácidos grasos".

3.4.2. Principio del análisis de enriquecimiento

El análisis de enriquecimiento funcional se basa en una pregunta estadística simple pero poderosa: **¿Aparecen los genes de mi lista (GDE) con una frecuencia mayor de la esperada por azar dentro de una categoría funcional (por ejemplo, un término GO) determinada?**

Para responder a esta pregunta, se construye una tabla de contingencia 2×2 para cada categoría funcional (ej. "respuesta inflamatoria"):

Genes en mi lista que pertenecen a "respuesta inflamatoria".

Genes en mi lista que NO pertenecen a "respuesta inflamatoria".

Genes fuera de mi lista (el resto del genoma) que pertenecen a "respuesta inflamatoria".

Genes fuera de mi lista que NO pertenecen a "respuesta inflamatoria".

A continuación, se aplica una prueba estadística (como el test exacto de Fisher o una prueba de hipergeométrica) para determinar si la proporción de genes de la categoría en mi lista es significativamente mayor que la proporción de esa categoría en el genoma de fondo. Si es así, se dice que la categoría está "**enriquecida**" en mi conjunto de GDE.

3.4.3. Interpretación biológica de los resultados de enriquecimiento

El resultado del análisis de enriquecimiento es una lista de términos GO y rutas KEGG significativamente sobrerrepresentados, junto con su p-valor ajustado (FDR). La interpretación de estos resultados permite pasar de una lista de genes a una **hipótesis biológica**.

Por ejemplo, si al analizar los GDE de la ERC encontramos un enriquecimiento significativo de términos GO como "organización de la matriz extracelular", "respuesta a TGF- β " y "migración celular", y rutas KEGG como "Vía de señalización de TGF-beta" y "Adhesión focal", podemos concluir que el proceso biológico principal alterado en nuestras muestras es la **fibrosis**, con una activación de la señalización profibrótica y un remodelado activo del tejido.

Esta interpretación permite conectar los hallazgos transcriptómicos con la fisiopatología conocida de la ERC, y ofrece una visión sistémica e integrada de los mecanismos moleculares que subyacen a la enfermedad, cumpliendo así con el objetivo último de este trabajo. Herramientas como `clusterProfiler` (Yu et al., 2012) facilitan enormemente este proceso, integrando el acceso a las bases de datos, el cálculo estadístico y la visualización de los resultados en gráficos como diagramas de barras o redes de términos.

CAPÍTULO 4

MARCO METODOLÓGICO

El presente capítulo describe de forma detallada el diseño metodológico, las fuentes de datos, los procedimientos de procesamiento y control de calidad, así como las técnicas bioinformáticas empleadas para alcanzar los objetivos planteados en este Trabajo Fin de Máster. La metodología fue diseñada bajo principios de robustez analítica, reproducibilidad computacional, trazabilidad metodológica y transparencia científica, aspectos esenciales en estudios basados en datos ómicos públicos.

El flujo de trabajo completo, desde la obtención de los datos hasta la generación de resultados finales, se resume en la Figura 4.1 (Anexo I). La implementación técnica del pipeline, incluyendo los scripts utilizados, la estructura del proyecto y los procedimientos de auditoría de resultados, se encuentra documentada en el Anexo II y en el repositorio GitHub asociado al proyecto.

4.1 Diseño del estudio

El presente trabajo corresponde a un estudio observacional, analítico y retrospectivo basado en el análisis secundario de datos transcriptómicos públicos.

Se considera observacional debido a que no existe intervención experimental sobre los sujetos incluidos en el estudio, limitándose el análisis a datos previamente generados y depositados en repositorios públicos. Se clasifica como analítico porque compara perfiles de expresión génica entre pacientes con enfermedad renal crónica (ERC) y sujetos control con el objetivo de identificar diferencias transcriptómicas asociadas al proceso patológico. Asimismo, se considera retrospectivo debido a que los datos fueron obtenidos previamente por otros investigadores y reutilizados en este estudio con fines analíticos específicos.

Este enfoque constituye una estrategia ampliamente aceptada en bioinformática y biología computacional, ya que permite maximizar el aprovechamiento de datos públicos disponibles bajo los principios de ciencia abierta y reproducibilidad científica. No obstante, la validez de los resultados depende de la calidad de los datos originales, de la adecuada caracterización de las muestras y de la rigurosidad de los procedimientos analíticos empleados.

Limitaciones de la plataforma transcriptómica

Los datos analizados proceden de tecnología de microarrays, la cual presenta ciertas limitaciones inherentes. Este tipo de plataformas permite evaluar únicamente transcritos previamente representados en las sondas incluidas en el diseño del array, a diferencia de tecnologías más recientes como RNA-seq, capaces de detectar nuevos transcritos, isoformas alternativas y ARN no codificantes.

A pesar de estas limitaciones, los microarrays continúan siendo una herramienta válida para estudios de expresión génica diferencial y reanálisis transcriptómicos, especialmente cuando se dispone de cohortes adecuadamente caracterizadas y datos de alta calidad.

4.2 Fuente de datos y criterios de selección

4.2.1 Repositorio de datos

Los datos empleados en este estudio fueron obtenidos del repositorio público Gene Expression Omnibus (GEO), mantenido por el National Center for Biotechnology Information (NCBI).

GEO constituye una de las principales plataformas internacionales para el almacenamiento, distribución y reutilización de datos de expresión génica procedentes de estudios transcriptómicos realizados mediante microarrays y secuenciación masiva. Su estructura estandarizada, la disponibilidad de metadatos asociados y la accesibilidad pública lo convierten en una fuente idónea para estudios de análisis secundario y reproducibilidad científica.

4.2.2 Selección del dataset

Tras una revisión de los conjuntos de datos disponibles relacionados con enfermedad renal crónica, se seleccionó el dataset **GSE12682**, correspondiente a muestras de tejido renal humano analizadas mediante la plataforma **GPL571 (Affymetrix Human Genome U133A 2.0 Array)**.

La cohorte analizada estuvo compuesta por un total de 52 muestras distribuidas de la siguiente forma:

- 23 muestras procedentes de pacientes con enfermedad renal crónica.
- 29 muestras correspondientes al grupo control.

Criterios de inclusión

- Muestras de tejido renal humano.
- Disponibilidad completa de datos de expresión génica.
- Metadatos suficientes para la correcta clasificación de grupos.
- Calidad técnica adecuada para el procesamiento bioinformático.

Criterios de exclusión

- Estudios con número insuficiente de réplicas biológicas.
- Muestras con información incompleta o inconsistente.
- Datos con problemas evidentes de calidad o anotación.

La selección de GSE12682 se fundamentó en la adecuada caracterización clínica de las muestras, su tamaño muestral relativamente equilibrado y la disponibilidad de metadatos suficientes para realizar un análisis transcriptómico robusto y reproducible.

El dataset GSE12682 fue descrito originalmente por Si et al. (2009) y se encuentra disponible públicamente a través del repositorio Gene Expression Omnibus (GEO) del National Center for Biotechnology Information (NCBI). La consulta y descarga de los datos se realizó durante el desarrollo de este Trabajo Fin de Máster utilizando el identificador GSE12682.

4.3 Preprocesamiento y control de calidad

4.3.1 Lectura y normalización de datos

La obtención de los datos y metadatos se realizó mediante el paquete GEOquery utilizando la función `getGEO(GSEMatrix = TRUE)`, que permite acceder a la matriz de series procesada depositada en el repositorio GEO.

Posteriormente, las muestras fueron sometidas a un procedimiento de normalización entre arrays mediante la función `normalizeBetweenArrays()` del paquete limma, con el objetivo de minimizar la variabilidad técnica y hacer comparables los niveles de expresión entre las muestras.

Debido a que múltiples sondas pueden corresponder a un mismo gen, se realizó un proceso adicional de colapsado de sondas, resumiendo los valores de expresión mediante la mediana para obtener una única medida de expresión por gen.

Como resultado, se obtuvo una matriz de expresión génica normalizada y resumida a nivel génico, adecuada para los análisis posteriores de expresión diferencial.

4.3.2 Evaluación de calidad

Con el objetivo de identificar posibles artefactos técnicos o muestras atípicas, se aplicaron diversas estrategias de control de calidad.

Las evaluaciones incluyeron:

- Gráficos de densidad de distribución de expresión.
- Diagramas de cajas (boxplots).
- Análisis de Componentes Principales (PCA).

Estos procedimientos permitieron verificar la homogeneidad global de las muestras, evaluar la consistencia de la normalización y detectar posibles valores atípicos que pudieran afectar los resultados posteriores.

La aplicación sistemática de estas técnicas contribuye a minimizar la influencia de variabilidad técnica y aumenta la confianza en la interpretación biológica de los hallazgos.

4.4 Análisis de expresión diferencial

4.4.1 Modelado estadístico mediante limma

La identificación de genes diferencialmente expresados se realizó mediante el paquete limma (Linear Models for Microarray Data), uno de los métodos más utilizados y validados para el análisis de datos transcriptómicos procedentes de microarrays.

Limma utiliza modelos lineales combinados con estimación bayesiana empírica de la varianza, permitiendo mejorar la estabilidad estadística de los resultados cuando se trabaja con tamaños muestrales moderados.

4.4.2 Corrección por comparaciones múltiples

Dado el elevado número de pruebas estadísticas realizadas simultáneamente, se aplicó el procedimiento de Benjamini-Hochberg para controlar la tasa de falsos descubrimientos (False Discovery Rate, FDR).

Se estableció un umbral de significación de:

- $FDR < 0.05$

Este criterio constituye el estándar habitualmente utilizado en estudios transcriptómicos.

4.4.3 Selección de genes diferencialmente expresados

Los genes fueron considerados diferencialmente expresados cuando cumplían simultáneamente los siguientes criterios:

1. $FDR < 0.05$
2. $|\log_2 \text{Fold Change}| \geq 1$

La combinación de ambos criterios permite asegurar tanto relevancia estadística como magnitud biológica suficiente de los cambios observados.

4.5 Análisis de enriquecimiento funcional

Con el objetivo de interpretar biológicamente los genes diferencialmente expresados, se realizó un análisis de enriquecimiento funcional mediante el paquete clusterProfiler.

Se empleó un enfoque de Over-Representation Analysis (ORA) para evaluar la sobre representación de términos funcionales en:

- Gene Ontology (GO)
- Kyoto Encyclopedia of Genes and Genomes (KEGG)

Para minimizar sesgos estadísticos se utilizó como universo de referencia el conjunto de genes efectivamente evaluados durante el análisis transcriptómico.

Se consideraron significativos los términos funcionales con:

- $FDR < 0.05$

Los resultados fueron posteriormente representados mediante gráficos tipo dotplot para facilitar su interpretación.

4.6 Reproducibilidad computacional y trazabilidad

Con el fin de garantizar la reproducibilidad del análisis, todo el pipeline fue implementado mediante scripts modulares desarrollados en lenguaje R.

La gestión de dependencias se realizó mediante el sistema **renv**, permitiendo registrar las versiones exactas de los paquetes utilizados durante el estudio mediante el archivo **renv.lock**.

Asimismo, el proyecto incorpora:

- Scripts documentados y organizados por etapas analíticas.
- Registros de ejecución (logs).
- Exportación de información de sesión (*sessionInfo*).
- Auditoría automática de resultados generados.
- Documentación de trazabilidad entre scripts y outputs.

La documentación técnica, los scripts, los resultados reproducibles y los materiales complementarios del proyecto se encuentran disponibles en el repositorio GitHub desarrollado específicamente para este Trabajo Fin de Máster:

<https://github.com/broncox456/tfm-erc-transcriptomica>

Este repositorio permite acceder al código fuente, la estructura completa del pipeline, los archivos de configuración, la documentación metodológica y los resultados generados durante el estudio.

Este enfoque permite que terceros puedan verificar, reproducir y auditar el flujo de trabajo completo de forma independiente, favoreciendo la transparencia científica y el cumplimiento de las buenas prácticas en investigación bioinformática.

4.7 Justificación metodológica

La metodología seleccionada responde a estándares ampliamente aceptados en estudios transcriptómicos basados en microarrays.

La utilización de limma se justifica por su robustez estadística, amplia validación en la literatura científica y excelente desempeño en contextos con tamaños muestrales moderados.

El empleo de un umbral $FDR < 0.05$ permite controlar adecuadamente el riesgo de falsos positivos, mientras que el criterio $|\log_2FC| \geq 1$ garantiza que los genes seleccionados presenten cambios biológicamente relevantes.

Se seleccionó un umbral de $|\log_2FC| \geq 1$ debido a que representa cambios de expresión de al menos dos veces entre grupos, criterio frecuentemente utilizado en estudios transcriptómicos exploratorios para priorizar genes con magnitud biológica relevante y reducir la inclusión de cambios de escasa relevancia funcional.

Por su parte, el análisis funcional mediante clusterProfiler facilita la interpretación biológica de los resultados y permite identificar procesos moleculares potencialmente implicados en la fisiopatología de la enfermedad renal crónica.

En conjunto, el pipeline desarrollado fue diseñado para maximizar la robustez estadística, la coherencia metodológica, la trazabilidad y la reproducibilidad computacional, asegurando que los resultados obtenidos sean interpretables, verificables y potencialmente reproducibles por otros investigadores.

CAPÍTULO 5.

RESULTADOS Y DISCUSIÓN

5.1 Control de calidad y análisis exploratorio

5.1.1 Introducción al control de calidad del dataset

El presente estudio se fundamenta en el análisis de un conjunto de datos transcriptómicos públicos obtenidos del repositorio Gene Expression Omnibus (GEO), que incluye muestras de tejido renal humano correspondientes a pacientes con enfermedad renal crónica (ERC) y controles sanos. Si bien el uso de datos públicos ofrece ventajas en términos de accesibilidad, reproducibilidad y eficiencia, también implica la necesidad de implementar procedimientos rigurosos de control de calidad para garantizar la validez de los resultados.

El objetivo principal de esta fase fue asegurar que las diferencias de expresión génica identificadas entre los grupos ERC y control reflejen verdaderas variaciones biológicas asociadas a la enfermedad, y no artefactos técnicos derivados del procesamiento experimental o de la heterogeneidad de las muestras.

Para ello, se desarrolló una estrategia de evaluación estructurada que incluyó: (i) análisis de distribuciones de expresión antes y después de la normalización, (ii) exploración de la estructura de varianza mediante análisis de componentes principales (PCA), y (iii) evaluación de patrones globales de expresión mediante heatmaps.

5.1.2 Evaluación de la distribución de la expresión génica

El análisis inicial se centró en la inspección de las distribuciones de intensidad de expresión génica mediante diagramas de caja (boxplots) y gráficos de densidad.




Figura 5.1. Distribución de los valores de expresión génica tras la normalización entre arrays mediante cuantiles implementada con `limma::normalizeBetweenArrays()`, evaluada mediante boxplots y curvas de densidad.

Los diagramas de caja correspondientes a los datos pre-normalización evidencian una marcada heterogeneidad entre las muestras, manifestada tanto en la dispersión de las medianas como en la amplitud de los rangos intercuartílicos. Estas diferencias reflejan la presencia de variabilidad técnica inherente al proceso experimental de los microarrays, incluyendo posibles efectos de lote, variaciones en la eficiencia de hibridación y diferencias en la intensidad de señal entre arrays.

Tras la aplicación de la normalización entre arrays mediante cuantiles implementada en la función `limma::normalizeBetweenArrays()`, se observa una clara homogeneización de las distribuciones de expresión génica. Las medianas de todas las muestras se alinean de manera prácticamente superponible y los rangos intercuartílicos se vuelven comparables, indicando una estabilización efectiva de la variabilidad técnica entre muestras. Asimismo, la reducción de la dispersión global sugiere que el ruido técnico ha sido sustancialmente minimizado sin comprometer la señal biológica subyacente.

La homogeneización observada es consistente con el objetivo de la normalización entre arrays, cuyo propósito es reducir la variabilidad técnica global y facilitar la comparación de los perfiles de expresión entre las muestras analizadas. La adecuada superposición de las distribuciones constituye un indicador de calidad que respalda la validez de los análisis posteriores de expresión diferencial.

Nota:

Elaboración propia a partir de datos de expresión génica procesados mediante normalización entre arrays implementada con `limma::normalizeBetweenArrays()`.

En conjunto, estos resultados confirman la eficacia del procedimiento de normalización aplicado, validando la idoneidad del dataset para el análisis de expresión diferencial. La eliminación de la variabilidad técnica no biológica representa un requisito indispensable para garantizar la fiabilidad estadística y la interpretabilidad biológica de los hallazgos obtenidos en fases posteriores del estudio.

5.1.3 Análisis de componentes principales (PCA)

El PCA permitió evaluar la estructura global de los datos en un espacio reducido de dimensiones, utilizando los 2.000 genes con mayor variabilidad.





Figura 5.2. Análisis de componentes principales (PCA) de las muestras renales.

Descripción:

El gráfico muestra la distribución de las muestras según los dos primeros componentes principales (PC1 y PC2). Se observa una separación parcial entre muestras ERC y controles a lo largo de PC1, indicando que la condición patológica representa una fuente relevante de variabilidad.

Nota:

Elaboración propia mediante análisis PCA. El PC1 explica el 24,2% de la variabilidad total y el PC2 el 15,4%. La mayor dispersión observada en las muestras ERC sugiere una heterogeneidad biológica intrínseca, consistente con la naturaleza multifactorial de la enfermedad. No se identificaron outliers evidentes, por lo que no fue necesario excluir muestras.

5.1.4 Análisis mediante heatmap de genes variables

El análisis se complementó con un heatmap construido a partir de los 30 genes diferencialmente expresados más significativos, seleccionados según su valor de significación estadística ajustada..

Figura 5.3. Heatmap basado en los 30 genes más significativos

Descripción:

El heatmap revela patrones de expresión diferenciados entre los grupos, con una clara agrupación jerárquica de las muestras según su condición clínica. Se identifican bloques de genes sobreexpresados e infraexpresados en ERC.

Nota:

Elaboración propia mediante pheatmap.

Este patrón confirma la existencia de programas transcripcionales coordinados asociados a la enfermedad.

5.1.5 Evaluación global del control de calidad

En conjunto, los análisis de control de calidad realizados permiten establecer con un alto grado de confianza que el dataset empleado presenta condiciones adecuadas para la realización de análisis transcriptómicos robustos. La integración de múltiples estrategias de evaluación —incluyendo análisis de distribuciones, reducción de dimensionalidad mediante PCA y visualización de patrones globales mediante heatmaps— proporciona una visión coherente y complementaria del comportamiento de los datos.

En primer lugar, la normalización entre arrays mediante cuantiles implementada con la función `limma::normalizeBetweenArrays()` demostró ser altamente efectiva en la reducción de la variabilidad técnica entre muestras. La homogeneización observada en las distribuciones de expresión génica tras la normalización indica que factores no biológicos, como diferencias en la intensidad de señal o variaciones derivadas del procesamiento experimental, fueron adecuadamente minimizados. Este paso es crítico, ya que la presencia de ruido técnico puede introducir sesgos significativos en los análisis posteriores de expresión diferencial.

En segundo lugar, el análisis de componentes principales evidenció la existencia de una señal biológica clara asociada a la condición de enfermedad renal crónica. La separación parcial de las muestras ERC respecto a los controles a lo largo del primer componente principal sugiere que la variabilidad dominante en el dataset está impulsada por diferencias biológicas relevantes y no por artefactos experimentales. Este hallazgo refuerza la validez del diseño del estudio y la idoneidad del dataset para responder a la pregunta de investigación planteada.

Asimismo, la heterogeneidad observada dentro del grupo de muestras ERC, reflejada en la dispersión a lo largo de componentes secundarios, es consistente con la naturaleza multifactorial y clínicamente heterogénea de la enfermedad renal crónica. Esta variabilidad no debe interpretarse como un defecto del dataset, sino como una representación fiel de la complejidad biológica inherente a la enfermedad, lo que añade valor interpretativo a los resultados obtenidos.

Por otra parte, no se identificaron muestras atípicas (outliers) que requirieran exclusión del análisis. La ausencia de valores extremos indica una adecuada consistencia interna del dataset y sugiere que todas las muestras contribuyen de manera equilibrada al análisis global, evitando distorsiones en la estimación de efectos diferenciales.

Finalmente, el análisis mediante heatmaps confirmó la coherencia interna de los grupos, mostrando patrones de expresión génica consistentes entre muestras de la misma condición y diferenciación clara entre grupos experimentales. Este resultado refuerza la existencia de programas transcripcionales coordinados asociados a la ERC.

En conjunto, estos hallazgos validan la calidad técnica y biológica del dataset, proporcionando una base sólida para la aplicación de métodos estadísticos avanzados en el análisis de expresión diferencial. La adecuada preparación de los datos en esta fase es determinante para garantizar la fiabilidad, reproducibilidad e interpretabilidad de los resultados posteriores.

5.2 Análisis de expresión diferencial

5.2.1 Identificación de genes diferencialmente expresados

Una vez completadas las etapas de preprocesamiento y control de calidad, se realizó el análisis de expresión diferencial con el objetivo de identificar genes cuya expresión presentara diferencias significativas entre las muestras correspondientes a pacientes con enfermedad renal crónica (ERC) y los controles.

Para ello se empleó el paquete limma (Linear Models for Microarray Data) del entorno Bioconductor, ampliamente utilizado para el análisis de datos transcriptómicos procedentes de microarrays. Este método utiliza modelos lineales combinados con

moderación bayesiana empírica de la varianza, lo que permite obtener estimaciones estadísticas robustas incluso en estudios con tamaños muestrales moderados.

La corrección por comparaciones múltiples se realizó mediante el procedimiento de Benjamini-Hochberg para controlar la tasa de falsos descubrimientos (False Discovery Rate, FDR). Se consideraron genes diferencialmente expresados aquellos que cumplieron simultáneamente los siguientes criterios:

- $FDR < 0,05$
- $|\log_2 \text{Fold Change}| \geq 1$

Este enfoque permitió identificar un conjunto de genes con relevancia estadística y biológica suficiente para su posterior interpretación funcional y fisiopatológica.




Figura 5.4. Volcano plot del análisis de expresión diferencial.

Descripción:

Se representan los cambios de expresión ($\log_2\text{FC}$) frente a la significación estadística. Se observan dos poblaciones bien definidas de genes sobreexpresados e infraexpresados en ERC.

Nota:

Elaboración propia mediante limma.

5.2.2 Visualización global mediante volcano plot

La representación gráfica de los resultados se realizó mediante un volcano plot, herramienta ampliamente utilizada para visualizar simultáneamente la magnitud de los cambios de expresión y su significación estadística.

Figura 5.4. Volcano plot del análisis de expresión diferencial.**Descripción:**

Se representan los cambios de expresión génica ($\log_2$ Fold Change) en el eje horizontal frente a la significación estadística ($-\log_{10}$ p ajustado) en el eje vertical. Se observan dos poblaciones bien definidas de genes diferencialmente expresados, correspondientes a genes sobreexpresados e infraexpresados en las muestras de ERC respecto a los controles.

Nota:

Elaboración propia mediante análisis de expresión diferencial utilizando limma en R/Bioconductor.

La distribución observada confirma la existencia de alteraciones transcriptómicas significativas asociadas a la enfermedad renal crónica y proporciona una visión global de la magnitud y dirección de los cambios de expresión identificados.

5.2.3 Principales genes diferencialmente expresados

La aplicación de los criterios de selección establecidos ($FDR < 0,05$ y $|\log_2 FC| \geq 1$) permitió identificar un total de 365 genes diferencialmente expresados entre las muestras correspondientes a pacientes con enfermedad renal crónica (ERC) y los controles.

De estos genes, 138 mostraron sobreexpresión en el grupo ERC, mientras que 227 presentaron infraexpresión respecto al grupo control.

La distribución observada evidencia una profunda remodelación transcriptómica asociada a la enfermedad renal crónica, caracterizada tanto por la activación de programas biológicos relacionados con procesos inflamatorios e inmunológicos como por la disminución de funciones específicas del tejido renal.

Entre los genes con mayor sobreexpresión se identificaron varios asociados a procesos inmunitarios y de señalización celular, mientras que entre los genes infraexpresados destacaron genes relacionados con la función glomerular y tubular renal.

Estos resultados sugieren que la progresión de la ERC se acompaña simultáneamente de mecanismos de activación inmunológica y pérdida progresiva de funciones especializadas del tejido renal.

5.2.4 Interpretación biológica

El análisis de expresión diferencial revela la coexistencia de dos procesos biológicos complementarios que caracterizan la enfermedad renal crónica (ERC): la activación de mecanismos inflamatorios e inmunológicos y la pérdida progresiva de funciones especializadas del tejido renal.

Por un lado, se observó la sobreexpresión de genes relacionados con la respuesta inmune y la inflamación, destacando PTPRC, IGLJ2, IGLV1-44, IGLC2 y MAPK13. La elevación de estos genes sugiere un incremento de la actividad inmunitaria local y la presencia de un microambiente inflamatorio persistente dentro del tejido renal. Este hallazgo es coherente con la participación de células inmunitarias infiltrantes y con la activación de vías de señalización asociadas a daño tisular crónico y remodelación del parénquima renal.

Por otro lado, se identificó una marcada infraexpresión de genes asociados a la estructura y función normal del glomérulo, entre ellos NPHS1 y NPHS2, que codifican proteínas esenciales del diafragma de filtración podocitaria. La disminución de la expresión de estos genes sugiere alteraciones en la integridad de la barrera de filtración glomerular y refleja la pérdida progresiva de funciones especializadas de las células renales. Asimismo, la reducción coordinada de genes vinculados a funciones renales específicas es compatible con procesos de lesión crónica, deterioro funcional y desdiferenciación celular.

En conjunto, estos resultados indican que la ERC se caracteriza por un desequilibrio progresivo entre mecanismos de daño y mecanismos de mantenimiento tisular. La activación sostenida de respuestas inmunológicas e inflamatorias, junto con la pérdida de funciones especializadas del tejido renal, configura una firma transcriptómica compatible con la progresión de la enfermedad, la remodelación tisular crónica y el deterioro funcional del riñón.

5.3 Análisis de enriquecimiento funcional

5.3.1 GO Proceso Biológico




Figura 5.5. Enriquecimiento en procesos biológicos (GO-BP).

Procesos principales:

- organización de matriz extracelular
- respuesta inflamatoria
- adhesión celular
- desarrollo renal

Estos resultados confirman el papel central de la fibrosis y la inflamación.

5.3.2 GO Componente Celular




Figura 5.6. Enriquecimiento en componentes celulares.

Predominio de:

- matriz extracelular
- región extracelular

Indica que la patología afecta principalmente el microambiente tisular.

5.3.3 GO Función Molecular




Figura 5.7. Enriquecimiento en funciones moleculares.

Funciones clave:

- unión a integrinas
- actividad de citoquinas
- interacción con factores de crecimiento

5.3.4 Rutas KEGG




Figura 5.8. Enriquecimiento en rutas KEGG.

Rutas principales:

- ECM-receptor interaction
- focal adhesion
- TGF-beta signaling
- PI3K-Akt

Estas rutas integran señales mecánicas, inflamatorias y metabólicas.

5.4 Integración fisiopatológica y mensaje central del estudio

Los resultados obtenidos permiten proponer un modelo fisiopatológico integrador en el que la enfermedad renal crónica se caracteriza por la interacción simultánea de mecanismos inflamatorios, inmunológicos y de pérdida progresiva de función renal especializada.

Los análisis de expresión diferencial evidenciaron la sobreexpresión de genes asociados a procesos inmunitarios y de respuesta inflamatoria, destacando PTPRC, IGLJ2, IGLV1-44, IGLC2 y MAPK13. Estos hallazgos sugieren la existencia de una activación persistente de vías relacionadas con la respuesta inmune y la inflamación crónica dentro del tejido renal.

Paralelamente, se observó una disminución significativa en la expresión de genes esenciales para la integridad estructural y funcional del glomérulo, particularmente NPHS1 y NPHS2. Ambos genes codifican proteínas fundamentales del diafragma de filtración podocitaria, por lo que su infraexpresión constituye un hallazgo compatible con daño glomerular progresivo y deterioro de la barrera de filtración renal.

Los análisis de enriquecimiento funcional complementan esta interpretación al identificar procesos biológicos relacionados con organización de matriz extracelular, adhesión celular, respuesta inflamatoria y remodelado tisular. De igual manera, las rutas enriquecidas identificadas mediante KEGG, incluyendo ECM-receptor interaction, focal adhesion, TGF-beta signaling y PI3K-Akt signaling, sugieren que la progresión de la enfermedad involucra mecanismos complejos de comunicación célula-matriz, inflamación crónica y remodelación estructural del tejido renal.

Es importante destacar que genes clásicos asociados a fibrosis renal, como COL1A1, COL3A1, FN1 o TGFB1, forman parte de mecanismos ampliamente descritos en la literatura científica relacionados con la progresión de la ERC. Sin embargo, en el presente estudio dichos genes no alcanzaron los criterios de significación establecidos, por lo que su mención debe interpretarse como parte del contexto biológico general de la enfermedad y no como hallazgos transcriptómicos diferenciales específicos de esta cohorte.

En conjunto, los resultados apoyan la hipótesis de que la enfermedad renal crónica representa un proceso biológico complejo en el que convergen inflamación persistente, alteraciones inmunológicas, remodelación de la matriz extracelular y pérdida progresiva de identidad funcional renal. Este modelo integrador es consistente con los mecanismos actualmente aceptados para explicar la progresión de la ERC y proporciona un marco biológico coherente para interpretar los hallazgos transcriptómicos obtenidos.

5.5 Discusión crítica en el contexto de la literatura

Los patrones transcriptómicos identificados en este estudio son consistentes con múltiples investigaciones previas sobre enfermedad renal crónica, aunque deben interpretarse dentro del contexto específico del diseño experimental y de las características de la cohorte analizada.

Diversos estudios han señalado que la progresión de la ERC se encuentra estrechamente relacionada con procesos inflamatorios, remodelado de la matriz extracelular y mecanismos profibróticos mediados por complejas redes de señalización celular (Liu, 2011). En el presente estudio, los análisis de enriquecimiento funcional identificaron rutas relacionadas con interacción célula-matriz extracelular, adhesión celular y señalización intracelular, incluyendo ECM-receptor interaction, focal adhesion, TGF-beta signaling y PI3K-Akt signaling. Aunque genes clásicos asociados a fibrosis renal, como COL1A1, COL3A1 o TGFB1, no alcanzaron los criterios de significación establecidos en esta cohorte, las rutas funcionales enriquecidas sugieren la participación de mecanismos biológicos compatibles con procesos de remodelado tisular y progresión de la enfermedad.

Los hallazgos obtenidos muestran una elevada concordancia con la literatura transcriptómica disponible en enfermedad renal crónica. En particular, Ju et al. (2015) describieron que la progresión de la ERC se asocia a la activación coordinada de programas inflamatorios, remodelado de matriz extracelular y mecanismos profibróticos, considerados actualmente componentes centrales de la fisiopatología renal progresiva. De forma consistente, en el presente estudio se identificó un enriquecimiento significativo de procesos biológicos y rutas relacionadas con inflamación, interacción célula-matriz extracelular, adhesión celular y señalización intracelular, reforzando la relevancia de estos mecanismos en el contexto de la enfermedad.

De igual manera, Hodgin et al. (2015) señalaron que el deterioro progresivo de la función renal se acompaña de alteraciones transcriptómicas asociadas a daño tubular, pérdida de funciones especializadas y reprogramación celular adaptativa. Aunque el presente trabajo se basa en un análisis global de tejido renal y no en compartimentos específicos, la alteración observada en genes y rutas relacionadas con función tubular y metabolismo celular resulta compatible con los patrones previamente descritos por dichos autores.

Por otra parte, Wilson et al. (2019) destacaron que diferentes etiologías de enfermedad renal crónica pueden converger hacia firmas transcriptómicas comunes caracterizadas por inflamación persistente, remodelado tisular y activación de programas profibróticos. Esta observación resulta especialmente relevante para interpretar los resultados del presente estudio, ya que los términos enriquecidos mediante Gene Ontology y las rutas identificadas en KEGG apuntan hacia mecanismos biológicos compartidos que parecen actuar como vías finales comunes de progresión renal independientemente de la causa inicial de la enfermedad.

En conjunto, la comparación con estudios transcriptómicos independientes sugiere que los hallazgos obtenidos no representan observaciones aisladas derivadas de una cohorte específica, sino que se integran dentro de un patrón biológico reproducible descrito de forma consistente en la literatura especializada. Aunque el presente trabajo no tiene como objetivo identificar biomarcadores inéditos ni proponer nuevos mecanismos fisiopatológicos, sí aporta una validación independiente de procesos moleculares ampliamente reconocidos en la progresión de la enfermedad renal crónica mediante un pipeline bioinformático reproducible basado en datos públicos.

Adicionalmente, aunque los microarrays presentan limitaciones frente a tecnologías como RNA-seq, su uso en este estudio permite acceder a cohortes bien caracterizadas y comparables con una extensa base de literatura histórica. Por tanto, este trabajo no pretende competir con estudios de mayor resolución, sino posicionarse como una validación robusta y reproducible de patrones transcriptómicos fundamentales en ERC.

En este sentido, los resultados obtenidos no introducen un mecanismo completamente nuevo, pero sí consolidan un marco integrador en el que inflamación, fibrosis y desdiferenciación celular actúan de forma coordinada. Este tipo de integración representa un aporte relevante desde el punto de vista conceptual.

Los hallazgos observados deben interpretarse dentro del contexto de las limitaciones inherentes al diseño observacional y al uso de datos transcriptómicos públicos, evitando inferencias causales directas sobre los mecanismos biológicos implicados.

5.6 Micro-crítica de los resultados y consideraciones metodológicas

Desde una perspectiva crítica, es importante analizar no solo los hallazgos obtenidos, sino también sus limitaciones y posibles fuentes de sesgo.

En primer lugar, la identificación de 365 genes diferencialmente expresados refleja un equilibrio entre sensibilidad y especificidad determinado por los umbrales aplicados ($FDR < 0,05$ y $|\log_2FC| > 1$). Un umbral más laxo habría incrementado el número de genes identificados, pero a costa de una mayor tasa de falsos positivos, mientras que criterios más estrictos habrían reducido la lista, posiblemente perdiendo señales biológicamente relevantes. Por tanto, el número de genes identificados debe interpretarse como una representación conservadora de los cambios transcriptómicos.

En segundo lugar, el uso de modelos lineales con moderación bayesiana (limma) proporciona robustez estadística, pero asume cierta homogeneidad en la varianza entre genes, lo que podría no cumplirse completamente en datasets heterogéneos. No obstante, esta limitación es ampliamente aceptada en estudios de microarrays y no compromete la validez general de los resultados.

Otro aspecto relevante es el posible sesgo derivado de la composición celular del tejido analizado. Al tratarse de datos bulk, los cambios observados pueden reflejar variaciones en la proporción de tipos celulares (por ejemplo, infiltración inflamatoria o pérdida de células epiteliales) además de cambios intrínsecos en la expresión génica. Esta limitación refuerza la necesidad de interpretar los resultados en un contexto tisular y no exclusivamente celular.

Finalmente, la ausencia de validación externa mediante un dataset independiente limita la generalización de los hallazgos. Sin embargo, la coherencia con la literatura existente y la consistencia interna del análisis proporcionan un respaldo razonable a la validez de los resultados.

5.7 Implicaciones traslacionales y relevancia del estudio

Los resultados obtenidos en este estudio aportan evidencia adicional sobre los mecanismos moleculares implicados en la progresión de la enfermedad renal crónica y refuerzan el potencial de la transcriptómica como herramienta para la comprensión de procesos fisiopatológicos complejos.

La identificación de alteraciones en genes relacionados con funciones glomerulares especializadas, particularmente NPHS1 y NPHS2, sugiere que la pérdida progresiva de integridad podocitaria constituye un componente relevante en la progresión de la enfermedad. Asimismo, la activación de programas asociados a inflamación e inmunidad refuerza el papel de la respuesta inflamatoria crónica como uno de los principales motores del daño renal persistente.

Por otra parte, el enriquecimiento de rutas relacionadas con interacción célula-matriz extracelular, adhesión celular y señalización intracelular pone de manifiesto la complejidad biológica de la ERC y destaca potenciales áreas de interés para futuras investigaciones orientadas al desarrollo de biomarcadores y estrategias terapéuticas dirigidas.

Más allá de los hallazgos específicos, este trabajo demuestra el valor de la reutilización de datos públicos y de los enfoques bioinformáticos reproducibles para generar conocimiento científicamente sólido en el ámbito de la nefrología. En este sentido, el estudio constituye un ejemplo de integración entre investigación biomédica, bioinformática y práctica clínica, contribuyendo a una mejor comprensión de los mecanismos moleculares asociados a la enfermedad renal crónica

5.8 Síntesis final del capítulo

En conjunto, los resultados obtenidos indican que la enfermedad renal crónica se caracteriza por una reprogramación transcriptómica compleja en la que convergen procesos de inflamación, fibrosis y pérdida de identidad celular. Este estudio aporta evidencia consistente de que estos procesos no actúan de forma independiente, sino como parte de un programa biológico integrado, lo que refuerza la necesidad de enfoques terapéuticos multidimensionales en la ERC. Estos resultados posicionan la ERC como una enfermedad caracterizada por la activación de programas transcripcionales coordinados, más que por alteraciones moleculares aisladas.

CAPÍTULO 6

CONCLUSIONES

6.1 Síntesis de los hallazgos principales

El presente Trabajo Fin de Máster tuvo como objetivo principal analizar las diferencias de expresión génica asociadas a la enfermedad renal crónica (ERC) mediante un enfoque transcriptómico basado en datos públicos y un pipeline bioinformático reproducible. Los resultados obtenidos confirman la existencia de un perfil transcriptómico diferencial entre muestras de ERC y controles sanos, caracterizado por la activación de procesos inflamatorios y de remodelado tisular, junto con la represión de funciones estructurales y metabólicas propias del tejido renal sano.

El análisis exploratorio inicial evidenció una separación parcial entre ambos grupos, reflejando la heterogeneidad biológica inherente a la ERC. A pesar de este solapamiento, el análisis de expresión diferencial permitió identificar un conjunto robusto de 365 genes diferencialmente expresados (138 sobreexpresados y 227 infraexpresados). Esta distribución refleja la coexistencia de dos fenómenos interrelacionados: la activación de programas patológicos asociados a inflamación y fibrosis, y la pérdida progresiva de funciones fisiológicas esenciales del tejido renal.

Desde una perspectiva molecular, los resultados obtenidos evidencian la coexistencia de procesos de activación inmunológica y pérdida progresiva de funciones renales especializadas. Entre los genes sobreexpresados destacaron PTPRC, IGLJ2, IGLV1-44, IGLC2 y MAPK13, asociados a mecanismos inmunitarios e inflamatorios. Por otra parte, genes como NPHS1 y NPHS2 presentaron una marcada infraexpresión, hallazgo compatible con alteraciones de la integridad podocitaria y deterioro progresivo de la función glomerular. La coherencia de estos resultados con los mecanismos fisiopatológicos descritos en la literatura respalda la validez biológica de la firma transcriptómica identificada.

El análisis de enriquecimiento funcional reveló una sobrerrepresentación significativa de procesos biológicos relacionados con la organización de la matriz extracelular, la respuesta inflamatoria, la adhesión celular y el desarrollo renal. Estos resultados sugieren la reactivación de programas génicos implicados en mecanismos de reparación maladaptativa frente al daño renal crónico.

La visualización mediante heatmap de los genes más significativos confirmó la existencia de patrones de expresión coordinados, organizados en módulos funcionales opuestos: un conjunto de genes sobreexpresados asociados a inflamación y fibrosis, y otro conjunto de genes infraexpresados vinculados a funciones renales especializadas. Esta organización modular aporta solidez adicional a la interpretación de los resultados.

Como limitación del presente estudio, los hallazgos obtenidos deberían ser validados en cohortes independientes o mediante la integración con otros niveles ómicos (proteómica o transcriptómica de célula única). Esta validación permitiría confirmar la robustez y generalización de las firmas transcriptómicas identificadas.

6.2 Implicaciones clínicas y científicas

Desde una perspectiva clínica, los resultados obtenidos consolidan el papel de la inflamación crónica y la fibrosis intersticial como ejes centrales en la progresión de la ERC. La identificación de genes y procesos biológicos asociados a estos mecanismos refuerza la necesidad de estrategias terapéuticas dirigidas no solo al control de los factores hemodinámicos y metabólicos, sino también a la modulación de la respuesta inflamatoria y fibrogénica.

La identificación de alteraciones transcriptómicas asociadas a funciones glomerulares especializadas, junto con la activación de mecanismos inmunológicos e inflamatorios, aporta información relevante sobre los procesos biológicos implicados en la progresión de la enfermedad renal crónica. Asimismo, la identificación de rutas relacionadas con remodelado tisular, interacción célula-matriz extracelular y respuesta inmune contribuye a generar hipótesis biológicas que podrían ser exploradas en futuras investigaciones orientadas al desarrollo de biomarcadores y nuevas estrategias terapéuticas.

Más allá de los hallazgos específicos, este trabajo refuerza la idea de que la enfermedad renal crónica no debe entenderse únicamente como una entidad definida por parámetros clínicos tradicionales, como la tasa de filtrado glomerular o la albuminuria, sino como un proceso dinámico caracterizado por alteraciones moleculares complejas.

Desde una perspectiva científica, este estudio demuestra la viabilidad de utilizar datos transcriptómicos públicos para generar conocimiento relevante en nefrología, siempre que se apliquen metodologías bioinformáticas rigurosas y reproducibles. La integración de control de calidad, análisis diferencial y enriquecimiento funcional permite construir una narrativa biológica coherente y comparable con estudios previos.

Asimismo, los resultados respaldan el potencial de la transcriptómica como herramienta clave en el desarrollo de la medicina de precisión aplicada a la nefrología. La caracterización molecular de la ERC constituye un paso fundamental hacia la estratificación de pacientes basada en perfiles biológicos, con implicaciones en el pronóstico y en la personalización de las intervenciones terapéuticas.

6.3 Implicaciones metodológicas y valor del enfoque bioinformático

Uno de los principales aportes de este trabajo reside en la implementación de un pipeline bioinformático reproducible, estructurado y documentado, alineado con los principios de ciencia abierta.

El uso de herramientas bioinformáticas consolidadas y ampliamente aceptadas en la comunidad científica, como limma y clusterProfiler, así como la revisión de metodologías basadas en paquetes como oligo, contribuye a la robustez del análisis y minimiza el riesgo de sesgos técnicos. Asimismo, la gestión del entorno computacional mediante renv garantiza la reproducibilidad de los resultados y facilita su validación independiente por otros investigadores.

La separación clara entre el análisis principal y los anexos técnicos contribuye a mejorar la legibilidad del documento sin comprometer la transparencia metodológica. Este enfoque resulta especialmente relevante en contextos con limitaciones de recursos experimentales, donde el aprovechamiento de datos públicos representa una estrategia eficiente para generar conocimiento científico. En este sentido, el trabajo no solo aporta resultados específicos sobre la ERC, sino que también constituye un ejemplo práctico de integración entre bioinformática y nefrología en un entorno académico estructurado.

6.4 Limitaciones del estudio

El presente estudio presenta varias limitaciones que deben ser consideradas en la interpretación de los resultados:

- El uso de microarrays implica un rango dinámico limitado y la imposibilidad de detectar nuevos transcritos, a diferencia de tecnologías como RNA-seq.
- La naturaleza retrospectiva del análisis introduce posibles sesgos derivados de la heterogeneidad en la obtención y procesamiento de las muestras.
- La ausencia de validación en una cohorte independiente limita la generalización de los resultados.
- La disponibilidad limitada de metadatos clínicos impide ajustar por variables como edad, comorbilidades o estadio de la enfermedad.

Estas limitaciones subrayan la necesidad de futuros estudios que integren datos multi-ómicos y cohortes clínicamente bien caracterizadas.

6.5 Líneas futuras de investigación

A partir de los resultados obtenidos y las limitaciones identificadas, se proponen las siguientes líneas de investigación:

1. Integración multi-ómica, combinando transcriptómica con datos epigenómicos, proteómicos y metabolómicos para una visión sistémica de la enfermedad.
2. Aplicación de tecnologías de célula única (scRNA-seq) para caracterizar la contribución de tipos celulares específicos en la patogénesis de la ERC.
3. Validación en cohortes clínicas independientes con seguimiento longitudinal, permitiendo evaluar el valor pronóstico de los genes identificados.
4. Estudios funcionales in vitro e in vivo orientados a establecer relaciones causales y evaluar el papel biológico de genes diferencialmente expresados identificados en este estudio, particularmente aquellos relacionados con funciones glomerulares especializadas y mecanismos inmunológicos asociados a la progresión de la enfermedad renal crónica.
5. Desarrollo de herramientas bioinformáticas accesibles que faciliten la aplicación de estos análisis en entornos clínicos e investigadores con recursos limitados.

6.6 Conclusión final

En conjunto, el presente Trabajo Fin de Máster ha cumplido de manera satisfactoria los objetivos planteados, demostrando la viabilidad de aplicar un enfoque transcriptómico riguroso y reproducible para el estudio de la enfermedad renal crónica mediante el uso de datos públicos y herramientas de código abierto.

Los resultados obtenidos evidencian la existencia de una firma transcriptómica diferencial caracterizada por la activación de procesos inflamatorios y de remodelado de la matriz extracelular, junto con la supresión de funciones estructurales y metabólicas propias del tejido renal sano. Estos hallazgos no solo son coherentes con la fisiopatología conocida de la enfermedad, sino que además refuerzan la validez biológica del enfoque empleado.

Desde una perspectiva científica, este trabajo contribuye a la comprensión de los mecanismos moleculares implicados en la progresión de la enfermedad renal crónica, integrando los resultados del análisis de expresión génica con procesos biológicos y rutas funcionales relevantes. Asimismo, pone de manifiesto el valor de la bioinformática como herramienta clave para la generación de conocimiento a partir de grandes volúmenes de datos ómicos.

En el ámbito clínico, la identificación de firmas moleculares reproducibles abre la puerta al desarrollo de biomarcadores con potencial utilidad en la estratificación de pacientes y en la predicción de la progresión de la enfermedad. En este sentido, la integración de datos transcriptómicos con variables clínicas representa una oportunidad estratégica para avanzar hacia modelos de atención más personalizados.

Finalmente, este trabajo refuerza la idea de que la enfermedad renal crónica debe ser entendida como un proceso dinámico y multifactorial, en el que convergen múltiples mecanismos moleculares interdependientes. La incorporación de enfoques transcriptómicos en la investigación y práctica clínica constituye un paso relevante hacia el desarrollo de la nefrología de precisión, orientada a mejorar la toma de decisiones clínicas y la optimización de las estrategias terapéuticas.

7. Declaración sobre el uso de herramientas de inteligencia artificial generativa

Durante el desarrollo de este Trabajo Fin de Máster se utilizaron herramientas de inteligencia artificial generativa como apoyo en tareas de revisión lingüística, mejora de redacción, organización de contenidos, corrección de estilo y optimización de la presentación escrita del documento.

Estas herramientas fueron empleadas exclusivamente como asistencia en la comunicación escrita y en la revisión documental, sin intervenir de forma autónoma en la generación de resultados científicos, análisis bioinformáticos, procesamiento de datos, interpretación de resultados ni elaboración de conclusiones.

Todas las decisiones metodológicas, la selección y procesamiento de los datos, el diseño del pipeline bioinformático, la ejecución de los análisis, la validación de los resultados, la elaboración de las figuras y tablas, así como la interpretación científica de los hallazgos, fueron realizadas y supervisadas directamente por el autor.

La responsabilidad intelectual, académica y científica del contenido de este trabajo corresponde íntegramente al autor, quien verificó y validó de manera independiente toda la información incluida en el documento final.

La presente declaración se incorpora en cumplimiento de los principios de integridad académica, transparencia científica y uso responsable de herramientas de inteligencia artificial en el ámbito universitario.

Bibliografía

- Bikbov, B., Purcell, C. A., Levey, A. S., Smith, M., Abdoli, A., Abebe, M., et al. (2020). Global, regional, and national burden of chronic kidney disease, 1990–2017: A systematic analysis for the Global Burden of Disease Study. *The Lancet*, 395(10225), 709–733. [https://doi.org/10.1016/S0140-6736\(20\)30045-3](https://doi.org/10.1016/S0140-6736(20)30045-3)
- Conesa, A., Madrigal, P., Tarazona, S., Gómez-Cabrero, D., Cervera, A., McPherson, A., et al. (2016). A survey of best practices for RNA-seq data analysis. *Genome Biology*, 17(1), 13. <https://doi.org/10.1186/s13059-016-0881-8>
- Davis, S., & Meltzer, P. S. (2007). GEOquery: A bridge between the Gene Expression Omnibus (GEO) and BioConductor. *Bioinformatics*, 23(14), 1846–1847. <https://doi.org/10.1093/bioinformatics/btm254>
- Duffield, J. S. (2014). Cellular and molecular mechanisms in kidney fibrosis. *Journal of Clinical Investigation*, 124(6), 2299–2306. <https://doi.org/10.1172/JCI72267>
- García-Maset, R., Bover, J., & Górriz, J. L. (2022). Guía de la Sociedad Española de Nefrología para la gestión de la enfermedad renal crónica. *Nefrología*, 42(1), 1–20. <https://doi.org/10.1016/j.nefro.2021.06.004>
- Gautier, L., Cope, L., Bolstad, B. M., & Irizarry, R. A. (2004). affy—Analysis of Affymetrix GeneChip data at the probe level. *Bioinformatics*, 20(3), 307–315. <https://doi.org/10.1093/bioinformatics/btg405>
- Gene Ontology Consortium. (2021). The Gene Ontology resource: Enriching a Gold mine. *Nucleic Acids Research*, 49(D1), D325–D334. <https://doi.org/10.1093/nar/gkaa1113>
- Gentleman, R. C., Carey, V. J., Bates, D. M., Bolstad, B., Dettling, M., Dudoit, S., et al. (2004). Bioconductor: Open software development for computational biology and bioinformatics. *Genome Biology*, 5(10), R80. <https://doi.org/10.1186/gb-2004-5-10-r80>
- Hinz, B. (2015). The extracellular matrix and transforming growth factor- β 1: Tale of a strained relationship. *Matrix Biology*, 47, 54–65. <https://doi.org/10.1016/j.matbio.2015.05.006>
- Hodgin, J. B., Borczuk, A. C., Nasr, S. H., Markowitz, G. S., Nair, V., Martini, S., et al. (2015). A molecular profile of focal segmental glomerulosclerosis from the NEPTUNE

cohort. *Journal of the American Society of Nephrology*, 26(10), 2489–2500. <https://doi.org/10.1681/ASN.2014070676>

Huber, W., Carey, V. J., Gentleman, R., Anders, S., Carlson, M., Carvalho, B. S., et al. (2015). Orchestrating high-throughput genomic analysis with Bioconductor. *Nature Methods*, 12(2), 115–121. <https://doi.org/10.1038/nmeth.3252>

Humphreys, B. D. (2018). Mechanisms of renal fibrosis. *Annual Review of Physiology*, 80, 309–326. <https://doi.org/10.1146/annurev-physiol-021317-121253>

Johnson, W. E., Li, C., & Rabinovic, A. (2007). Adjusting batch effects in microarray expression data using empirical Bayes methods. *Biostatistics*, 8(1), 118–127. <https://doi.org/10.1093/biostatistics/kxj037>

Ju, W., Nair, V., Smith, S., Zhu, L., Shedden, K., Song, P. X. K., et al. (2015). Tissue transcriptome-driven identification of epidermal growth factor as a chronic kidney disease biomarker. *Science Translational Medicine*, 7(316), 316ra193. <https://doi.org/10.1126/scitranslmed.aac7071>

Kalantar-Zadeh, K., Jafar, T. H., Nitsch, D., Neuen, B. L., & Perkovic, V. (2021). Chronic kidney disease. *The Lancet*, 398(10302), 786–802. [https://doi.org/10.1016/S0140-6736\(21\)00519-5](https://doi.org/10.1016/S0140-6736(21)00519-5)

Kanehisa, M., Furumichi, M., Sato, Y., Ishiguro-Watanabe, M., & Tanabe, M. (2023). KEGG: Integrating viruses and cellular organisms. *Nucleic Acids Research*, 51(D1), D587–D592. <https://doi.org/10.1093/nar/gkac963>

KDIGO. (2024). Clinical practice guideline for the evaluation and management of chronic kidney disease. *Kidney International*, 105(4 Suppl.), S1–S194. <https://kdigo.org/guidelines/ckd-evaluation-and-management/>

Kuppe, C., Ibrahim, M. M., Kranz, J., Zhang, X., Ziegler, S., Perales-Patón, J., et al. (2021). Decoding myofibroblast origins in human kidney fibrosis. *Nature*, 589(7841), 281–286. <https://doi.org/10.1038/s41586-020-2941-1>

Liu, Y. (2011). Cellular and molecular mechanisms of renal fibrosis. *Nature Reviews Nephrology*, 7(12), 684–696. <https://doi.org/10.1038/nrneph.2011.149>

- Meng, X. M., Nikolic-Paterson, D. J., & Lan, H. Y. (2015). Inflammatory processes in renal fibrosis. *Nature Reviews Nephrology*, 11(7), 398–411. <https://doi.org/10.1038/nrneph.2015.89>
- Parikh, C. R., Coca, S. G., Thiessen-Philbrook, H., Shlipak, M. G., Koyner, J. L., Wang, Z., et al. (2020). Biomarkers of acute and chronic kidney disease. *Nature Reviews Nephrology*, 16(5), 293–305. <https://doi.org/10.1038/s41581-020-0255-2>
- Ritchie, M. E., Phipson, B., Wu, D., Hu, Y., Law, C. W., Shi, W., & Smyth, G. K. (2015). limma powers differential expression analyses for RNA-sequencing and microarray studies. *Nucleic Acids Research*, 43(7), e47. <https://doi.org/10.1093/nar/gkv007>
- Ruiz-Ortega, M., Rayego-Mateos, S., Lamas, S., Ortiz, A., & Rodríguez-Díez, R. R. (2020). Targeting the progression of chronic kidney disease. *Nature Reviews Nephrology*, 16(5), 269–288. <https://doi.org/10.1038/s41581-019-0248-y>
- Schmid, H., Boucherot, A., Yasuda, Y., Henger, A., Brunner, B., Eichinger, F., Nitsche, A., Kiss, E., Bleich, M., Gröne, H. J., Nelson, P. J., Schlöndorff, D., & Kretzler, M. (2006). Modular activation of nuclear factor- κ B transcriptional programs in human diabetic nephropathy. *Diabetes*, 55(11), 2993–3003. <https://doi.org/10.2337/db06-0477>
- Si, H., Banga, R. S., Kapitsinou, P., Ramaiah, M., Lawrence, J., Kambhampati, G., Gruenwald, A., Bottinger, E., Glicklich, D., Tellis, V., Greenstein, S., Thomas, D. B., Pullman, J., Fazzari, M., & Susztak, K. (2009). Human and murine kidneys show gender- and species-specific gene expression differences in response to injury (N.^o GSE12682) [Dataset]. Gene Expression Omnibus, National Center for Biotechnology Information. <https://www.ncbi.nlm.nih.gov/geo/query/acc.cgi?acc=GSE12682>
- Wilson, P. C., Wu, H., Kirita, Y., Uchimura, K., Ledru, N., Rennke, H. G., et al. (2019). The single-cell transcriptomic landscape of early human diabetic nephropathy. *Proceedings of the National Academy of Sciences*, 116(39), 19619–19625. <https://doi.org/10.1073/pnas.1908706116>
- Yu, G., Wang, L. G., Han, Y., & He, Q. Y. (2012). clusterProfiler: An R package for comparing biological themes among gene clusters. *OMICS: A Journal of Integrative Biology*, 16(5), 284–287. <https://doi.org/10.1089/omi.2011.0118>

ANEXO I.




Figura A1. Density plot de las distribuciones de expresión génica normalizada

Descripción:

Distribución de las intensidades de expresión génica tras la normalización mediante RMA, mostrando homogeneidad entre muestras.

Nota:

Elaboración propia.




Figura A2. Heatmap extendido de los 100 genes con mayor variabilidad

Descripción:

Mapa de calor de los genes con mayor varianza, mostrando patrones globales de expresión y agrupación de muestras.

Nota:

Elaboración propia mediante pheatmap en R.

Gen	log2FC	p-valor ajustado	Regulación
IGLJ2	4.09	5.00E-06	Sobreexpresado
BMS1P20	4.09	5.00E-06	Sobreexpresado
IGLV1-44	3.9	1.80E-05	Sobreexpresado
IGLC1	3.84	6.10E-05	Sobreexpresado
IGLV3-25	3.82	1.90E-05	Sobreexpresado
IGLC2	3.73	2.50E-05	Sobreexpresado
IGLC3	3.73	2.50E-05	Sobreexpresado
IGLV4-3	3.69	4.80E-04	Sobreexpresado
CYAT1	3.69	4.80E-04	Sobreexpresado
IGLC7	3.68	9.90E-05	Sobreexpresado
NDNF	-4.62	1.70E-05	Infraexpresado
PCOLCE2	-4.47	1.20E-05	Infraexpresado
NES	-3.72	4.00E-05	Infraexpresado
SEMA3G	-3.66	5.10E-05	Infraexpresado
CLIC5	-3.63	2.50E-05	Infraexpresado
CHI3L1	-3.58	3.60E-04	Infraexpresado
SPOCK1	-3.56	4.70E-05	Infraexpresado
NPHS2	-3.52	8.10E-05	Infraexpresado
DPP6	-3.39	4.50E-05	Infraexpresado
TNNT2	-3.38	3.10E-04	Infraexpresado

Tabla 5.1. Top 20 genes diferencialmente expresados en ERC

Nota:

Se presentan los genes más diferencialmente expresados, seleccionados por su alta magnitud de cambio (log2FC) y significación estadística (FDR < 0,05). Estos resultados reflejan los principales procesos biológicos alterados en la enfermedad renal crónica. El listado completo se encuentra disponible en la Tabla A1 (Anexos).

La presencia de valores coincidentes entre algunos genes, particularmente IGLJ2 y BMS1P20, se interpretó en el contexto de la anotación de sondas de microarrays, donde una misma señal o sondas altamente relacionadas pueden mapear a transcritos, loci inmunoglobulínicos o regiones génicas estrechamente relacionadas. Por tanto, estos valores no fueron interpretados como eventos independientes absolutos, sino como parte de un patrón transcriptómico común asociado a sobreexpresión de genes de inmunoglobulinas y posible infiltrado inflamatorio/linfoplasmocitario.

ANEXO II.

PIPELINE BIOINFORMÁTICO DEL ANÁLISIS TRANSCRIPTÓMICO

1. Introducción

El presente anexo describe de forma estructurada el pipeline bioinformático implementado para el análisis transcriptómico diferencial en enfermedad renal crónica. Su objetivo es proporcionar una visión clara del flujo de trabajo, desde la adquisición de los datos hasta la obtención de los resultados finales.

El pipeline fue diseñado bajo principios de modularidad, automatización y reproducibilidad, permitiendo la ejecución completa del análisis sin intervención manual.

2. Descripción general del pipeline

El flujo de análisis se organiza en las siguientes etapas:

1. Validación del entorno
2. Descarga de datos desde GEO
3. Curación de metadatos
4. Normalización de expresión génica
5. Control de calidad
6. Expresión diferencial
7. Enriquecimiento funcional
8. Generación de resultados

3. Estructura funcional

Cada etapa se implementa mediante scripts independientes:

- scripts/01_validate.R
- R/01_download.R
- R/02_metadata.R
- R/03_normalize.R
- R/04_qc.R
- R/05_de.R
- R/06_enrichment.R
- R/07_figures_tables.R

4. Ejecución del pipeline

El pipeline completo se ejecuta mediante:

```
source("scripts/run_pipeline.R")
```

Este script coordina la ejecución secuencial de todas las etapas del análisis.

5. Entradas y salidas

Entradas:

- Datos transcriptómicos (GEO)
- Archivos de configuración
- Metadatos

Salidas:

- Tablas de genes diferencialmente expresados
- Resultados de enriquecimiento
- Figuras (PCA, volcano, heatmap)
- Logs y sessionInfo

6. Consideraciones finales

El diseño modular del pipeline permite su reutilización y extensión en estudios futuros, garantizando trazabilidad y coherencia analítica.

ANEXO III.

REPRODUCIBILIDAD DEL ANÁLISIS BIOINFORMÁTICO

1. Entorno computacional

- Sistema operativo: Windows
- R: 4.5.2
- Bioconductor: 3.22
- Gestión de dependencias: renv

El archivo renv.lock permite reconstruir exactamente el entorno.

2. Estructura del proyecto

El proyecto sigue una organización modular:

config/

data/

R/

scripts/

results/

logs/

renv.lock

3. Ejecución del pipeline

```
source("scripts/run_pipeline.R")
```

Incluye:

- Validación
- Descarga
- Normalización
- QC
- Expresión diferencial
- Enriquecimiento
- Generación de resultados

4. Control de entorno

Validado mediante:

```
renv::status()
```

Resultado:

No issues found — entorno consistente.

5. Resultados reproducibles

Tablas:

- TFM_Top20_DE.tsv
- TFM_Top20_UP.tsv
- TFM_Top20_DOWN.tsv

Figuras:

- PCA
- Volcano
- Heatmap
- GO enrichment

6. Restauración

```
install.packages("renv")
```

```
renv::restore()
```

```
source("scripts/run_pipeline.R")
```

7. Declaración de reproducibilidad

El análisis es completamente reproducible mediante:

- control de dependencias
- pipeline automatizado
- logs
- sessionInfo
- estructura modular

FRAGMENTOS REPRESENTATIVOS DEL SCRIPT

A3.1 Validación del proyecto

```
stopifnot(  
  dir.exists("data"),  
  dir.exists("scripts"),  
  dir.exists("results")  
)
```

A3.2 Normalización

```
library(oligo)  
eset <- rma(raw_data)
```

A3.3 Expresión diferencial

```
library(limma)  
  
design <- model.matrix(~ group)  
fit <- lmFit(eset, design)  
fit <- eBayes(fit)
```

```
deg_results <- topTable(fit, coef = 2, adjust.method = "BH", number = Inf)
```

A3.4 Enriquecimiento

```
library(clusterProfiler)  
  
ego <- enrichGO(  
  gene = sig_genes,  
  OrgDb = org.Hs.eg.db,  
  ont = "BP"  
)
```

Estos fragmentos ilustran las principales etapas del análisis y están alineados con el pipeline completo implementado.